

Trabajo de Fin de Grado

Grado en Inteligencia Artificial

Exploración de técnicas de Inteligencia Artificial para asistentes de cocina

Ana Herrero Zumarraga

Dirección

Director 1: Iñigo Lopez Gazpio

19 de junio de 2026

Agradecimientos

En primer lugar, me gustaría expresar mi más sincero agradecimiento a mi tutor, Iñigo Lopez Gazpio, por su constante guía, paciencia y dedicación a lo largo de este proyecto. Sus correcciones y valiosos consejos han sido fundamentales para ayudarme a dar forma a mis ideas iniciales y para encaminar esta investigación hacia el mejor resultado posible.

A mi familia y amigos, por estar siempre presentes y por involucrarse de manera tan activa en el desarrollo de este trabajo.

Por último, quiero dar las gracias de corazón a mis amigas y compañeras de la facultad. Gracias por haber sido mi mayor apoyo a lo largo de todos estos años de grado, por compartir las largas jornadas de estudio y por hacer de este camino universitario una experiencia inolvidable. Sin vosotras, este viaje no habría sido el mismo.

Resumen

En este trabajo se presenta una exploración de diferentes técnicas del campo de la Inteligencia Artificial para la creación de un sistema inteligente de recomendación de recetas culinarias basado en las prioridades logísticas y nutricionales del usuario. En la sociedad actual, la planificación dietética eficiente se ha convertido en un desafío debido al ritmo de vida acelerado y a la saturación de información, lo que genera problemas comunes como el desperdicio de alimentos y la dificultad para mantener hábitos saludables adaptados a los recursos disponibles en el hogar. El desarrollo de este tipo de aplicaciones no solo optimiza el aprovechamiento de la despensa doméstica reduciendo el gasto económico, sino que mitiga la fatiga de decisión del consumidor al ofrecer alternativas viables, personalizadas y nutricionalmente equilibradas en tiempo real. Tras contextualizar este problema, el proyecto detalla la ingesta, limpieza y estructuración del conjunto de datos mediante técnicas de Procesamiento del Lenguaje Natural (NLP) y Reconocimiento de Entidades Nombradas (NER). Sobre esta base, se desarrollan y contrastan diferentes espacios latentes utilizando embeddings de palabras con los modelos Word2Vec y FastText, los cuales permiten capturar la semántica gastronómica y resolver la variabilidad léxica de ingredientes con significados equivalentes. Estos modelos alimentan el núcleo del sistema, donde se implementan los casos de uso principales a través de una metaheurística de búsqueda local estocástica (Búsqueda Local Iterada, ILS) y la optimización multiobjetivo mediante el cálculo del Frente de Pareto, logrando equilibrar con precisión la disponibilidad de la nevera con las propiedades nutricionales y temporales requeridas. Finalmente, se realiza un estudio exploratorio utilizando modelos basados en BERT para evaluar el potencial de las arquitecturas de Transformers en la clasificación avanzada de textos culinarios, consolidando una arquitectura robusta, eficiente y orientada a su despliegue práctico.

Objetivos de Desarrollo Sostenible

El desarrollo de este Trabajo de Fin de Grado, centrado en la recomendación personalizada de recetas culinarias y a la extracción automatizada de recetas viables a partir de una base de datos de gran tamaño se alinea de manera directa con los compromisos globales de la Agenda 2030 para el Desarrollo Sostenible.

Específicamente, el impacto de esta herramienta se enmarca en tres objetivos fundamentales: el ODS 12: Producción y Consumo Responsables (en particular, la meta 12.3 enfocada en la reducción del desperdicio de alimentos), el ODS 3: Salud y Bienestar y el ODS 9: Industria, Innovación e Infraestructura.

A nivel global, un tercio de los alimentos producidos para el consumo humano se pierde o se desperdicia, ocurriendo una parte significativa de esta ineficiencia en los hogares debido a una planificación deficiente o a la falta de flexibilidad al gestionar los ingredientes disponibles. Este proyecto mitiga directamente dicha problemática al diversificar las alternativas de uso de los ingredientes disponibles, ampliando el abanico de opciones culinarias del usuario más allá de su repertorio habitual.

Por otro lado, la malnutrición y los hábitos alimentarios poco saludables constituyen uno de los principales factores de riesgo para el desarrollo de enfermedades crónicas no transmisibles. El sistema diseñado contribuye al ODS 3 al integrar funciones objetivo explícitas destinadas a la optimización nutricional.

Finalmente, este trabajo realiza una contribución significativa al ODS 9, el cual promueve la innovación y la resiliencia tecnológica a través de la investigación científica. La gestión y el procesamiento de grandes volúmenes de datos no estructurados representa uno de los desafíos más complejos en la ingeniería del software actual. En este contexto, el proyecto aporta valor al desarrollar una infraestructura digital capaz de transformar un catálogo masivo y heterogéneo de información gastronómica en un entorno de conocimiento estructurado y accesible.

Índice de contenidos

Índice de contenidos	VII
Índice de figuras	X
Índice de tablas	XI
1 Introducción	1
1.1. Contexto y motivación	1
1.2. Planteamiento del problema	2
1.3. Trabajos relacionados	3
1.3.1. Sistemas de Recomendación Gastronómica Basados en Contenido	3
1.3.2. Modelado de Conocimiento y Representaciones Vectoriales Latentes	3
1.3.3. Optimización Metaheurística y Enfoques Multiobjetivo	4
1.4. Enfoque metodológico y recorrido experimental	4
1.5. Estructura del documento	6
2 Planificación y gestión del proyecto	7
2.1. Objetivos del proyecto	7
2.2. Planificación temporal estimada y diagrama de Gantt	8
2.2.1. Análisis de desvíos y desafíos técnicos sobre la planificación	8
2.2.2. Infraestructura tecnológica y entornos de hardware	9
3 Construcción y Modelado del Corpus Culinario	11
3.1. Obtención de los datos: Web Scraping	11
3.1.1. Justificación de la Infraestructura Tecnológica	12
3.1.2. Arquitectura del Spider y Estrategia de Extracción en Dos Fases	12
3.1.3. Especificación del Modelo de Datos Extraído	13
3.2. Normalización y Categorización de Ingredientes	14
3.2.1. Análisis Empírico de la Variabilidad en el Dataset Real	14
3.2.2. Planteamiento Metodológico: Análisis Comparativo	16
3.2.3. Preprocesamiento Heurístico y Limpieza Basada en Reglas	16
3.2.4. Evaluación de Calidad y Análisis de Redundancia	17
3.2.5. Extracción cream y Normalización Semántica mediante Reconocimiento de Entidades Nombradas (NER)	19

3.2.6.	Ingeniería de Atributos y Homogeneización del Perfil de la Receta . . .	21
4	Modelado Semántico y Embeddings	23
4.1.	Word2Vec: Contextualización, Implementación y Resultados	23
4.1.1.	Estrategia de Modelado de Contexto Gastronómico	24
4.1.2.	Parametrización e Hiperparámetros del Modelo	24
4.1.3.	Resolución de Frases Compuestas mediante Agregación Vectorial . .	25
4.1.4.	Resultados y Validación Empírica del Espacio Latente	25
4.2.	FastText: Contextualización, Implementación y Resultados	27
4.2.1.	Parametrización e Hiperparámetros del Modelo	27
4.2.2.	Resolución de Frases Compuestas mediante Agregación Vectorial . .	28
4.2.3.	Resultados y Validación de Cohesión Espacial	29
4.3.	Comparación y Análisis de Resultados	30
4.3.1.	Divergencias Estructurales en la Topología del Espacio	30
4.3.2.	Impacto de la Información Sub-palabra (<i>Subword Information</i>)	31
4.3.3.	Selección de la Arquitectura Óptima para el Recomendador	31
4.3.4.	Validación Topológica mediante Agrupamiento Jerárquico (Dendro- grama)	32
5	Experimentación de metaheurísticas	35
5.1.	Optimización monobjetivo y cobertura semántica en el espacio latente . . .	35
5.1.1.	Algoritmo Baseline: Coincidencia Determinista de Conjuntos	35
5.1.2.	Algoritmo de Búsqueda Local Estocástica (Random Local Search) . . .	38
5.1.3.	Búsqueda Local Guiada con Mecanismo de Perturbación Condicionada	42
5.1.4.	Evaluación de Alternativas Heurísticas mediante Simulated Annealing	45
5.2.	Optimización Multicriterio y Modelado Multiobjetivo en el Espacio Latente .	50
5.2.1.	Enfoque Multicriterio mediante Agregación Lineal Estática	50
5.2.2.	Análisis Comparativo del Impacto del Preprocesamiento en las Meta- heurísticas	52
5.2.3.	Planteamiento del Enfoque Multiobjetivo Real y la Frontera de Pareto	53
5.2.4.	Resultados Experimentales de la Frontera de Pareto bajo Imputación por Tendencia Central	55
5.2.5.	Resultados Experimentales de la Frontera de Pareto mediante Filtrado de Registros Incompletos	56
5.3.	Conclusiones Generales	57
6	Exploración de transformers	61
6.1.	Selección y Justificación del Modelo Base: BETO	61
6.2.	Curación del Corpus y Selección de Atributos Gastronómicos	62
6.3.	Finetuning del Clasificador de Afinidad Culinaria	62
6.3.1.	Análisis de Convergencia y Curvas de Aprendizaje	63
6.4.	Evaluación Experimental del Espacio de Similitud Contextual	64
6.4.1.	Discusión de Resultados y Comportamiento del Modelo	64
6.4.2.	Conclusión del Enfoque Basado en Transformers	66

ÍNDICE DE CONTENIDOS

IX


Conclusiones	67
Limitaciones del trabajo	68
Líneas de trabajo futuro	69

Índice de figuras

2.1.	Diagrama de Gantt del proyecto.	8
3.1.	Flujo metodológico del proceso de extracción en dos fases.	12
3.2.	Taxonomía de inconsistencias y representación lógica de ruido en el catálogo de ingredientes crudo.	15
3.3.	Estudio de calidad y distribución taxonómica de los ingredientes tras la aplicación del pipeline de limpieza manual.	18
3.4.	Prueba empírica de redundancia en la detección de ingredientes por métodos heurísticos.	19
3.5.	Estudio de calidad y distribución taxonómica de los ingredientes tras la optimización mediante el modelo NER.	21
3.6.	Análisis comparativo de la dispersión léxica y resolución del problema de redundancia.	21
4.1.	Dendrograma de agrupamiento jerárquico basado en la distancia del coseno para el top 50 de ingredientes más comunes en el espacio de embedding.	34
6.1.	Evolución del <i>Training Loss</i> segmentada por <i>splits</i> de entrenamiento a lo largo de los pasos de optimización para el clasificador gastronómico.	63

Índice de tablas

2.1.	Distribución de la infraestructura tecnológica según la carga de cómputo.	10
4.1.	Matriz cruzada de similitud del coseno para la validación de cohesión y separación del espacio vectorial en Word2Vec.	26
4.2.	Matriz cruzada de similitud del coseno para la validación de cohesión y separación del espacio vectorial en FastText.	29
4.3.	Matriz de decisión técnica para la selección del modelo de embeddings definitivo.	31
5.1.	Resultados de recomendación del algoritmo Baseline mediante optimización exacta de overlap.	37
5.2.	Resultados empíricos de la búsqueda local bajo diferentes escenarios de hiperparámetros.	41
5.3.	Métricas de rendimiento e impacto del índice de exploración en la Búsqueda Local Avanzada.	44
5.4.	Indicadores estadísticos de rendimiento combinados a 1,000 iteraciones según la complejidad del inventario bajo la representación continua original.	47
5.5.	Indicadores estadísticos consolidados a 500 iteraciones utilizando la función de vecindario discreto de Jaccard en ambos entornos.	49
5.6.	Indicadores estadísticos de rendimiento del algoritmo ILS Continuo a 500 iteraciones.	53
5.7.	Resultados de la Frontera de Pareto para las soluciones no dominadas empleando sustitución por la media.	55
5.8.	Resultados de la Frontera de Pareto para las soluciones no dominadas tras la eliminación de registros incompletos.	56
6.1.	Métricas de asignación de similitud contextual en el inventario cerrado de la despena de prueba.	64



Introducción

1.1. Contexto y motivación

El ritmo de vida contemporáneo y la evolución de los hábitos de consumo han transformado de manera significativa la gestión alimentaria en el ámbito doméstico. En este contexto, la planificación culinaria diaria se enfrenta de forma recurrente a varios desafíos: el aprovechamiento ineficiente de los ingredientes disponibles, la tendencia a repetir un repertorio limitado de menús y la sobrecarga cognitiva asociada a decidir qué cocinar. Este Trabajo de Fin de Grado surge de la motivación de abordar dichas problemáticas mediante técnicas de ingeniería de datos e inteligencia artificial.

Una de las motivaciones centrales del proyecto radica en optimizar el uso del inventario alimentario del hogar, permitiendo al usuario identificar recetas viables a partir de los ingredientes ya disponibles en su nevera o despensa. Este aprovechamiento más eficiente no solo puede contribuir a reducir el gasto económico, sino que también se alinea con modelos de consumo más sostenibles orientados a minimizar el desperdicio alimentario.

Junto a ello, el proyecto persigue fomentar una mayor diversidad en la selección de recetas. Ante catálogos masivos de información culinaria, los usuarios tienden a recurrir de manera repetitiva a platos conocidos, lo que limita la variedad de la dieta y dificulta el descubrimiento de nuevas alternativas. En este sentido, un sistema de recomendación inteligente puede actuar como apoyo en la toma de decisiones, proponiendo opciones adaptadas a los recursos disponibles y reduciendo el esfuerzo asociado a la búsqueda manual.

El interés de este trabajo no reside únicamente en la utilidad práctica del sistema, sino también en el reto técnico que plantea. La información culinaria disponible en la web suele presentarse en formato no estructurado, con una elevada variabilidad léxica y semántica en la forma de expresar ingredientes, cantidades y características de las recetas. Por ello, el desarrollo de un asistente de cocina de estas características requiere combinar procesos de extracción y normalización de datos, técnicas de representación semántica y estrategias de

optimización capaces de operar bajo restricciones reales.

De este modo, la propuesta se sitúa en la intersección entre el procesamiento del lenguaje natural, el modelado semántico y la optimización algorítmica, con el objetivo de transformar una tarea cotidiana en un proceso más eficiente, flexible y personalizado.

1.2. Planteamiento del problema

La recomendación automática de recetas a partir de los ingredientes disponibles en un entorno doméstico constituye un problema considerablemente más complejo de lo que podría sugerir una búsqueda literal sobre una base de datos. A diferencia de otros sistemas de recuperación de información, en este dominio no basta con localizar coincidencias exactas entre una consulta y un conjunto de registros: es necesario interpretar expresiones lingüísticas heterogéneas, resolver equivalencias semánticas entre ingredientes y evaluar simultáneamente múltiples restricciones de viabilidad.

Una de las principales dificultades reside en la propia naturaleza de los datos. Las recetas disponibles en la web suelen estar redactadas en lenguaje natural libre y presentan una estructura altamente variable, tanto en la forma de nombrar los ingredientes como en la inclusión de cantidades, unidades de medida, técnicas de preparación o descriptores contextuales dentro de un mismo campo textual. Esta heterogeneidad impide aplicar de manera fiable mecanismos directos de emparejamiento exacto, ya que una misma entidad culinaria puede aparecer fragmentada en numerosas variantes léxicas o morfosintácticas.

A esta dificultad se añade un segundo problema: incluso si se consigue normalizar el texto y aislar correctamente los ingredientes, la recomendación no puede reducirse a una comprobación binaria de presencia o ausencia. En un contexto real, la viabilidad de una receta depende también de la posibilidad de aceptar sustituciones razonables entre ingredientes semánticamente próximos, así como de la capacidad del sistema para priorizar unas soluciones frente a otras según criterios adicionales, como el tiempo de preparación, la dificultad técnica o el perfil nutricional del plato.

Por tanto, el problema abordado en este trabajo no consiste únicamente en recuperar recetas relacionadas con una lista de ingredientes, sino en construir una representación computacional del dominio culinario que permita operar con flexibilidad semántica y, sobre esa base, diseñar algoritmos capaces de explorar de forma eficiente un espacio de soluciones condicionado por restricciones múltiples y, en ocasiones, contrapuestas.

Desde esta perspectiva, el reto se articula en varias decisiones técnicas interdependientes. En primer lugar, es necesario transformar un corpus web no estructurado en una base de conocimiento coherente y explotable. En segundo lugar, debe definirse una representación semántica capaz de reducir la variabilidad léxica de los ingredientes y modelar relaciones de afinidad culinaria. En tercer lugar, resulta necesario analizar qué estrategias de búsqueda y optimización permiten recomendar recetas viables bajo restricciones logísticas y nutricionales. Finalmente, también es pertinente explorar si modelos contextuales basados en Transformers pueden complementar o superar algunas de las limitaciones de los embeddings estáticos en

tareas de afinidad y sustitución de ingredientes.

En consecuencia, este TFG plantea el desarrollo del asistente de cocina como una investigación progresiva en la que cada fase metodológica responde a una limitación detectada en la anterior: desde la adquisición y normalización del dato, hasta la comparación de representaciones semánticas y la evaluación de distintos enfoques de optimización y modelado contextual.

Con el fin de articular formalmente el alcance de estas metodologías, las metas generales y específicas derivadas de este planteamiento se desglosan con detalle en el Capítulo 2.

1.3. Trabajos relacionados

El desarrollo de asistentes culinarios y sistemas de recomendación orientados al dominio gastronómico ha experimentado un auge notable en la última década, impulsado por la digitalización masiva de recetas y el creciente interés por la nutrición personalizada [1]. La literatura científica aborda este desafío desde tres vertientes metodológicas interconectadas: la arquitectura de los sistemas de recomendación basados en contenido, la representación semántica de ingredientes mediante espacios vectoriales latentes y la aplicación de metaheurísticas para la optimización multiobjetivo de menús.

1.3.1. Sistemas de Recomendación Gastronómica Basados en Contenido

Los sistemas de recomendación tradicionales se han fundamentado históricamente en técnicas de filtrado colaborativo o filtrado basado en contenido [2]. No obstante, en el ámbito de la cocina doméstica, el filtrado colaborativo presenta limitaciones severas debido al problema del arranque en frío (*cold-start*) y a la naturaleza hiperpersonalizada e impredecible de las existencias de una despensa real.

Por este motivo, las investigaciones más recientes se han desplazado hacia aproximaciones basadas puramente en el contenido de las recetas, donde el motor de búsqueda evalúa las propiedades explícitas del plato frente a las restricciones del usuario [3]. Trabajos previos enfocan este problema mediante el uso de bases de datos relacionales estrictas o grafos de conocimiento. Si bien estos enfoques garantizan una alta fidelidad en la coincidencia exacta de términos, adolecen de una rigidez matemática que genera elevados índices de falsos negativos ante sutiles variaciones léxicas, un obstáculo que el presente trabajo mitiga mediante la flexibilidad continua de las metaheurísticas.

1.3.2. Modelado de Conocimiento y Representaciones Vectoriales Latentes

La gestión de la heterogeneidad textual y el ruido en el lenguaje libre (v.g., unidades de medida, sinónimos o técnicas de corte) ha sido tradicionalmente abordada mediante la construcción manual de ontologías gastronómicas estructuradas. Sin embargo, el mantenimiento y la escalabilidad de estas estructuras semánticas rígidas resultan inviables ante corpus dinámicos extraídos de la web.

Para superar esta barrera, la literatura moderna de Procesamiento del Lenguaje Natural (PLN) introdujo la hipótesis distributiva [4] y los modelos de *embeddings* estáticos como *Word2Vec* [5, 6], demostrando que es posible proyectar palabras en espacios vectoriales continuos de baja dimensionalidad donde la cercanía geométrica (calculada mediante la similitud del coseno [7]) equivale a la afinidad conceptual. En el ámbito culinario, esto permite agrupar automáticamente ingredientes por familias biológicas o funcionales.

A pesar de su éxito para identificar sinónimos evidentes, la literatura reciente señala que los *embeddings* estáticos sufren de una falta de sensibilidad al contexto discursivo de la oración [8], un problema crítico cuando un ingrediente secundario o decorativo se confunde con la proteína troncal del plato. Esta limitación ha motivado la transición hacia arquitecturas basadas en *Transformers* y modelos de lenguaje contextuales específicos del dominio, tales como *Food-BERT* [1], una evolución que se evalúa y discute en las fases finales de esta investigación como alternativa superior a los umbrales de sustitución estáticos [9].

1.3.3. Optimización Metaheurística y Enfoques Multiobjetivo

Una vez resuelta la capa semántica, la evaluación simultánea de miles de recetas frente a múltiples restricciones (disponibilidad de insumos, cotas temporales, perfiles macro-nutricionales y niveles de dificultad) constituye un problema de optimización combinatoria de alta complejidad [10].

La aproximación metodológica convencional consiste en agregar linealmente todos los criterios en una única función objetivo escalar ponderada por un vector de pesos estáticos [3]. No obstante, autores como Coello Coello [11] y Barr [12] argumentan que este enfoque de agregación introduce un sesgo arbitrario y destruye la naturaleza real del problema, el cual está gobernado por criterios intrínsecamente en conflicto.

Para resolver este dilema de manera eficiente sin incurrir en costes computacionales prohibitivos, la literatura avala el uso de algoritmos de Búsqueda Local Estocástica [13], técnicas de recocido simulado (*Simulated Annealing*) basadas en los equilibrios probabilísticos de Boltzmann [14, 15], y estrategias de optimización multiobjetivo real apoyadas en el concepto de la dominancia de Pareto [3]. Este TFG se posiciona en esta última frontera metodológica, evaluando comparativamente cómo operan dichas metaheurísticas estocásticas sobre espacios continuos para devolver un catálogo equilibrado de soluciones Pareto-óptimas adaptadas al hogar [16].

1.4. Enfoque metodológico y recorrido experimental

El presente trabajo no aborda el desarrollo del asistente culinario como una implementación lineal de técnicas previamente cerradas, sino como un proceso de exploración experimental progresiva en el que cada fase metodológica surge como respuesta a las limitaciones observadas en la etapa anterior. Desde esta perspectiva, el objetivo no consiste únicamente en construir un recomendador funcional, sino en analizar qué combinación de estrategias

de procesamiento del lenguaje natural, representación semántica y optimización resulta más adecuada para el dominio gastronómico.

La primera fase del trabajo se centra en la construcción del corpus y en la transformación de un conjunto masivo de recetas web en una base de conocimiento estructurada. Esta etapa incluye la extracción automática de datos, la definición del modelo de información de la receta y la normalización de los ingredientes. En este punto, el problema principal no es todavía la recomendación en sí misma, sino la necesidad de disponer de datos consistentes sobre los que pueda operar cualquier algoritmo posterior. El análisis de esta fase permite comprobar que los enfoques heurísticos basados exclusivamente en reglas son útiles como línea base de limpieza, pero insuficientes para resolver de forma robusta la variabilidad léxica del dominio culinario, lo que conduce a la incorporación de un modelo de reconocimiento de entidades.

Una vez consolidado un inventario canónico de ingredientes, la segunda fase aborda la representación semántica del dominio. En ella se entrenan y comparan diferentes espacios latentes con el fin de estudiar hasta qué punto capturan relaciones de proximidad culinaria útiles para la recomendación. La comparación entre Word2Vec y FastText no se plantea como un ejercicio independiente, sino como una decisión estructural del sistema: elegir la geometría semántica sobre la que se apoyarán posteriormente los algoritmos de búsqueda. Esta fase permite determinar qué modelo preserva mejor la afinidad funcional entre ingredientes y cuál resulta más adecuado para operar en escenarios de sustitución y cobertura parcial del inventario.

Sobre esta base, la tercera fase del trabajo traslada la representación semántica al problema de recomendación propiamente dicho. El recorrido experimental comienza con un algoritmo baseline de coincidencia exacta que actúa como referencia determinista. Las limitaciones observadas en este enfoque, especialmente su rigidez ante sinonimias, reformulaciones y sustituciones plausibles, justifican la transición hacia estrategias de búsqueda local estocástica guiadas por similitud semántica. A partir de ahí, se comparan diferentes variantes heurísticas y distintos mecanismos de exploración del espacio de soluciones, con el propósito de analizar no solo la calidad de las recetas recomendadas, sino también la interacción entre la topología del espacio latente y el comportamiento de cada metaheurística.

La cuarta fase amplía el problema desde un escenario monobjetivo hacia un marco multicriterio y multiobjetivo más próximo al uso real de un asistente de cocina. En este punto, el solapamiento de ingredientes deja de ser el único criterio relevante y pasa a combinarse con restricciones temporales, técnicas y nutricionales. En una primera aproximación, estas dimensiones se integran mediante funciones de agregación lineal. Sin embargo, dado que dicha formulación exige fijar pesos de importancia de manera previa, el trabajo evoluciona posteriormente hacia un enfoque multiobjetivo basado en la dominancia de Pareto, permitiendo recuperar un conjunto de soluciones no dominadas que reflejan compromisos diferentes entre objetivos contrapuestos.

Finalmente, la última fase incorpora una exploración de modelos contextuales basados en Transformers mediante BETO. Esta línea no se introduce como un bloque aislado, sino como respuesta a una limitación detectada en las fases previas: aunque los embeddings estáticos

permiten modelar cercanía semántica global entre ingredientes, presentan dificultades para captar con precisión el papel funcional de cada ingrediente dentro del contexto específico de una receta. La experimentación con BETO permite, por tanto, analizar hasta qué punto un modelo contextual puede complementar el motor principal del sistema en tareas de afinidad culinaria y validación de sustituciones.

En conjunto, el recorrido del trabajo sigue una lógica encadenada: construir el dato, normalizarlo, representarlo semánticamente, explotar esa representación mediante algoritmos de recomendación y, finalmente, explorar arquitecturas contextuales como vía de mejora. Esta secuencia da coherencia al conjunto de experimentos desarrollados y constituye el hilo conductor de la investigación.

1.5. Estructura del documento

La memoria se organiza en seis capítulos principales, además de las conclusiones finales. Tras este capítulo introductorio, el Capítulo 2 presenta la planificación del proyecto, la distribución temporal del trabajo y la infraestructura tecnológica empleada durante el desarrollo.

El Capítulo 3 describe el proceso de construcción del corpus culinario, incluyendo la extracción automatizada de recetas, la normalización de ingredientes y la consolidación de una base de conocimiento estructurada.

A continuación, el Capítulo 4 aborda el modelado semántico del dominio mediante embeddings, comparando distintas arquitecturas con el fin de seleccionar la representación más adecuada para el sistema de recomendación.

El Capítulo 5 constituye el núcleo experimental del trabajo y recoge los distintos casos de uso desarrollados, desde los enfoques basados en coincidencia exacta hasta los algoritmos de búsqueda local, la optimización multicriterio y el análisis multiobjetivo mediante frontera de Pareto.

Posteriormente, el Capítulo 6 explora el uso de modelos contextuales basados en Transformers, evaluando el potencial de BETO para tareas de afinidad culinaria y sustitución de ingredientes.

Finalmente, el documento se cierra con un apartado de conclusiones en el que se sintetizan los principales resultados obtenidos, se discuten las limitaciones del trabajo y se plantean posibles líneas de mejora y continuidad futura.

Planificación y gestión del proyecto

2.1. Objetivos del proyecto

El presente proyecto se fundamenta en la consecución de los siguientes objetivos y subobjetivos:

1. **Ingesta, estructuración y normalización del catálogo de datos.**
 - a) Consolidar un repositorio en formato JSON que almacene de manera íntegra el catálogo de recetas y sus metadatos asociados.
 - b) Diseñar un flujo (*pipeline*) de preprocesamiento y limpieza para estandarizar la nomenclatura de los ingredientes y las características.
2. **Modelado de espacios latentes mediante representaciones vectoriales.**
 - a) Generar y entrenar *embeddings* semánticos de palabras para codificar las relaciones y similitudes conceptuales entre ingredientes.
3. **Desarrollo y evaluación de los escenarios de búsqueda y optimización.**
 - a) Implementar un algoritmo heurístico que optimice la selección de recetas basándose en la métrica de solapamiento (*overlap*) de ingredientes disponibles.
 - b) Extender el motor de búsqueda para la obtención de soluciones óptimas sujetas simultáneamente al solapamiento y a restricciones específicas de características.
4. **Exploración experimental de arquitecturas Transformer.**
 - a) Evaluar el rendimiento de modelos basados en BERT para la extracción de representaciones vectoriales contextuales en el dominio gastronómico.

2.2. Planificación temporal estimada y diagrama de Gantt

El desarrollo de este proyecto está dimensionado para una dedicación total de 300 horas de trabajo. Con el objetivo de garantizar la viabilidad del desarrollo y un control riguroso del progreso, el tiempo se ha distribuido estratégicamente entre 6 fases. Esta distribución temporal y la secuenciación en cascada de las tareas se encuentran ilustradas en el Diagrama de Gantt incluido al final de este apartado.

1. Ingesta y Preprocesamiento de Datos (60 horas)
2. Creación de Embeddings de Ingredientes (40 horas)
3. Desarrollo de Algoritmos y Escenarios de Búsqueda (85 horas)
4. Exploración de Tecnología BERT (25 horas)
5. Estudio y comparación de resultados (40 horas)
6. Redacción de la Memoria Final (50 horas)




Figura 2.1: Diagrama de Gantt del proyecto.

2.2.1. Análisis de desvíos y desafíos técnicos sobre la planificación

A pesar de la hoja de ruta trazada inicialmente en el cronograma, el desarrollo de este proyecto de investigación se ha enfrentado a imprevistos de carácter empírico y metodológico propios de la experimentación con modelos estocásticos y de Aprendizaje Profundo. Estos desafíos obligaron a reajustar los tiempos y enfocar esfuerzos adicionales en las siguientes fases críticas:

- **Comportamiento anómalo en la optimización monoobjetivo (*Simulated Annealing*):** Durante la evaluación del bloque de metaheurísticas, los experimentos iniciales con el algoritmo de *Simulated Annealing* arrojaron resultados sorprendentes e inesperados en comparación con las aproximaciones locales más simples. Este comportamiento anómalo obligó a pausar el cronograma previsto para realizar un estudio en profundidad más exhaustivo. Fue necesario analizar detalladamente las dinámicas de convergencia y la estructura del espacio de búsqueda para comprender la naturaleza de dichos resultados, lo que supuso una desviación temporal pero enriqueció notablemente el rigor del análisis comparativo.
- **Incertidumbre en el *fine-tuning* y arquitectura de entrada de los *Transformers*:** La integración de modelos del lenguaje basados en la arquitectura Transformer presentó un reto de diseño complejo. No existía una heurística clara sobre cuál era la mejor estrategia para realizar el *fine-tuning* aplicado a nuestro dominio específico, ni qué estructura óptima debían presentar los datos de entrada (por ejemplo, la delimitación entre utilizar únicamente títulos, listas de ingredientes estructuradas o el texto narrativo completo de las recetas). Además, las primeras iteraciones ofrecieron resultados no óptimos. Superar este bloqueo requirió un proceso iterativo de pruebas de ensayo y error dilatando la fase de modelado de texto.
- **Evolución iterativa del corpus de entrenamiento para el *NER*:** La fase de extracción y normalización de entidades requirió un esfuerzo continuo y no lineal. Se detectaron problemas persistentes en la regularización y estandarización de los ingredientes debido a la alta variabilidad y ambigüedad del lenguaje culinario bruto. Esto obligó a desarrollar, expandir y refinar de manera continua la base de datos de entrenamiento para el modelo *NER* (*Named Entity Recognition*), un proceso que exigió más ciclos de anotación, curación y reentrenamiento de los inicialmente estimados en la planificación para poder garantizar la robustez del sistema de etiquetado.

2.2.2. Infraestructura tecnológica y entornos de hardware

Para garantizar la viabilidad del procesamiento del corpus y soportar la carga computacional asociada a las diferentes técnicas de Inteligencia Artificial implementadas, se ha diseñado un entorno de ejecución híbrido. Este enfoque divide las tareas entre una estación de trabajo local y una infraestructura de computación en la nube, optimizando así el uso de los recursos disponibles según los requerimientos de cada fase:

- **Entorno de desarrollo local (*Visual Studio Code*):** La mayor parte del ciclo de vida del software, incluyendo las fases de *web scraping*, limpieza heurística de datos, diseño de la arquitectura modular y la ejecución de los algoritmos de búsqueda local básicos, se llevó a cabo en un entorno local utilizando el entorno de desarrollo *Visual Studio Code*. Este entorno proporcionó la flexibilidad necesaria para la depuración del código y la orquestación inicial del proyecto sin depender de conectividad externa constante.

- **Entorno de computación de alto rendimiento (Google Colab):** Aquellos procesos con un coste computacional crítico o con requisitos de paralelización masiva en GPU se delegaron a la plataforma en la nube *Google Colab*. El uso de esta infraestructura fue fundamental para aprovechar los recursos de hardware acelerado (entornos con acceso a GPU de altas prestaciones) necesarios en las siguientes tareas:
 - La extracción y entrenamiento continuo de la base de datos para el modelo *NER*.
 - La ejecución y simulación de las trayectorias estocásticas del algoritmo de *Simulated Annealing*, debido a la necesidad de evaluar múltiples estados en la optimización monoobjetivo.
 - El proceso de *fine-tuning* de la arquitectura Transformer, cuyo coste computacional por el mecanismo de atención es inviable en entornos de CPU convencionales.
 - La generación y obtención de las matrices de embeddings vectoriales mediante *Word2Vec*, que requería el procesamiento eficiente de grandes volúmenes de texto.

Para aportar una visión más sintetizada de la distribución de estas herramientas y su propósito en el proyecto, la Tabla 2.1 recoge la especificación del entorno tecnológico empleado.

Entorno / Plataforma	Componente Clave	Propósito en el Proyecto
<i>Visual Studio Code</i>	CPU & Entorno Local	Desarrollo base, <i>scraping</i> y heurísticas simples.
<i>Google Colab</i>	Aceleración GPU Cloud	Entrenamiento de <i>NER</i> y <i>fine-tuning</i> de BERT.
<i>Google Colab</i>	Memoria RAM Ampliada	Vectores <i>Word2Vec</i> .
<i>Ecosistema Software</i>	Python, PyTorch, HuggingFace	Librerías núcleo de IA y optimización utilizadas.

Tabla 2.1: Distribución de la infraestructura tecnológica según la carga de cómputo.

Construcción y Modelado del Corpus Culinario

La viabilidad de cualquier sistema inteligente de recomendación gastronómica está intrínsecamente ligada a la calidad, estructura y fidelidad semántica de su base de conocimiento. Las recetas de cocina disponibles de forma masiva en la web constituyen un ecosistema de datos altamente complejo y heterogéneo; la información se presenta habitualmente en formato de lenguaje libre, plagada de variaciones tipográficas, redundancias léxicas y una ausencia total de taxonomías estandarizadas que diferencien, por ejemplo, las cantidades o técnicas de corte del nombre base de un ingrediente. Si un motor de optimización o un modelo de lenguaje se alimentan directamente de esta fuente en bruto, el ruido del texto anularía cualquier capacidad de generalización algorítmica.

Por consiguiente, este capítulo detalla el flujo completo de ingeniería de datos diseñado para transformar este catálogo caótico en una estructura de conocimiento limpia, coherente y matemáticamente explotable. Este proceso abarca desde la ingesta inicial, hasta la normalización semántica del vocabulario mediante técnicas de Procesamiento de Lenguaje Natural (PLN) y el aislamiento de entidades clave a través de reconocimiento avanzado de texto. La curación de este corpus constituye la cimentación estructural indispensable sobre la que se entrenarán los espacios latentes vectoriales y se ejecutarán las metaheurísticas de optimización en las etapas posteriores del proyecto.

3.1. Obtención de los datos: Web Scraping

La construcción de la base empírica de este proyecto requirió el diseño y desarrollo de un sistema de recolección automatizada de datos a gran escala. Para ello, se seleccionó como fuente la plataforma web *RecetasGratis*. Esta elección se fundamenta en criterios de calidad y uniformidad: las recetas que se recopilan en esta página han sido redactadas por un equipo de

cocineros y profesionales (según la información proporcionada en su web), lo que proporciona validez a las recetas. Además, el corpus textual se encuentra redactado íntegramente en castellano, lo que elimina sesgos de traducción en las fases posteriores.

Desde el punto de vista técnico, el portal presenta una estructura basada en código HTML semántico y predecible, lo que facilita la aplicación de técnicas de *web scraping* para la transformación de fuentes de información no estructuradas en registros de datos altamente estructurados [17].

3.1.1. Justificación de la Infraestructura Tecnológica

Para la implementación del flujo de extracción se evaluaron diferentes alternativas tecnológicas, decantándose finalmente por el uso de *Scrapy*. A diferencia de librerías síncronas convencionales como *BeautifulSoup* o *Requests*, que ejecutan las peticiones de manera secuencial bloqueando el hilo de ejecución, *Scrapy* es un *framework* de alto rendimiento construido sobre una arquitectura asíncrona orientada a eventos [18].

Esta permite gestionar de manera concurrente cientos de peticiones HTTP, optimizando el uso del ancho de banda y la CPU del sistema. Asimismo, provee de forma nativa mecanismos robustos para el manejo de fallos en la capa de red, reintentos automáticos de peticiones caídas (*retries*), filtrado de URLs duplicadas y una separación limpia de responsabilidades mediante componentes especializados.

3.1.2. Arquitectura del Spider y Estrategia de Extracción en Dos Fases

El diseño del agente de extracción (*Spider*) se fragmentó estratégicamente en dos fases de ejecución consecutivas e independientes con el fin de maximizar la modularidad del código, mitigar el consumo de memoria en tiempo de ejecución y asegurar la tolerancia a fallos del sistema [19]. El flujo metodológico general que gobierna ambas fases se ilustra de forma detallada en la Figura 3.1.




Figura 3.1: Flujo metodológico del proceso de extracción en dos fases.

Fase 1: Mapeo del Catálogo y Descubrimiento de URLs

La primera fase consistió en un proceso de navegación y descubrimiento (*crawling*). El *Spider* fue parametrizado con las URLs semilla correspondientes a las categorías macro de la web (aperitivos, platos principales, postres, condimentos, entre otros). A través de selectores basados en expresiones XPath y selectores CSS, el algoritmo aisló las estructuras de paginación del portal.

El script recorrió de forma recursiva cada índice de categoría, abstrayendo exclusivamente el título identificativo y la URL absoluta de cada receta de manera secuencial. El resultado de este primer subproceso fue la consolidación de un archivo intermedio en formato JSON que actuó como un índice maestro, evitando realizar peticiones redundantes a la infraestructura del servidor de origen.

Fase 2: Extracción Semántica y Análisis de Contenido

La segunda fase comprende el *scraping* propiamente dicho. Utilizando el archivo JSON generado en la fase anterior como una cola de tareas persistente, un segundo proceso asíncrono se encargó de iterar sobre cada una de las URLs recolectadas. Al realizar la petición a la página de la receta concreta, el motor de *Scrapy* parseó el árbol DOM (*Document Object Model*) para extraer los nodos de información específicos mediante reglas de emparejamiento estrictas.

3.1.3. Especificación del Modelo de Datos Extraído

De cada entidad gastronómica procesada en la segunda fase, se diseñó un esquema de extracción orientado a recuperar la información técnica, estructural y nutricional necesaria para nutrir los algoritmos de recomendación subsiguientes. Específicamente, se aisló y estructuró el siguiente conjunto de atributos:

1. **Título de la receta:** Cadena de texto que identifica la entidad y sirve como etiqueta de salida del sistema.
2. **URL de origen:** Almacenada como identificador único universal.
3. **Características técnicas del cocinado:** Metadatos categóricos fundamentales para el planteamiento de restricciones en el motor de optimización:
 - *Duración:* Tiempo estimado de elaboración en formato de notación de tiempo con unidades textuales (2 h y 23 m).
 - *Número de comensales:* Valor que delimita el rendimiento de las porciones del plato.
 - *Dificultad:* Atributo categórico ordinal (bajo, medio, alto) que califica la complejidad técnica de la receta.
4. **Lista de ingredientes (Cuerpo empírico):** Cada elemento de esta lista representa un ingrediente individual e integra de forma textual tanto la entidad del ingrediente como sus cuantificadores (unidades y medidas).

5. **Elaboración paso a paso:** Secuencia textual ordenada de las instrucciones técnicas de preparación.
6. **Perfil composicional y valores nutricionales:** Vector de variables macro-nutricionales asociadas a la receta por cada 100 gramos o por porción estándar:
 - *Calorías (kcal), Proteínas (g), Grasas (g), Carbohidratos (g) y Fibra (g).*

Como resultado final de esta arquitectura de extracción, el sistema completó con éxito el procesamiento del portal, logrando consolidar un *dataset* final compuesto por **12.554 recetas únicas**. El corpus final destaca por una alta diversidad taxonómica, abarcando de forma equilibrada desde platos de alta densidad proteica (platos principales) hasta elementos complementarios (condimentos y salsas), dotando al proyecto de un espectro de datos lo suficientemente amplio y heterogéneo como para garantizar la robustez de los modelos algorítmicos multiobjetivo.

3.2. Normalización y Categorización de Ingredientes

El núcleo funcional de un sistema de recomendación gastronómica basado en el inventario de la nevera reside en su capacidad para realizar emparejamientos lógicos precisos entre las existencias del usuario y los requisitos de las recetas. Sin embargo, dado que el catálogo de datos se ha construido a partir de fuentes redactadas en lenguaje natural libre, los registros de ingredientes exhiben intrínsecamente un elevado nivel de ambigüedad, variabilidad morfosintáctica y dispersión léxica.

Si se introdujeran los datos crudos directamente en el motor de optimización, el sistema sufriría de una severa desconexión semántica; por ejemplo, sería incapaz de identificar que cadenas como 'dos huevos grandes', '5 yemas de huevo' o 'un huevo de corral' comparten la misma entidad base esencial. Esta falta de homogeneidad multiplicaría artificialmente la dimensionalidad del vocabulario, fragmentando una misma entidad conceptual en decenas de variantes textuales independientes.

Por consiguiente, se hace indispensable el diseño de un ecosistema de normalización y categorización que reduzca la granularidad del lenguaje, unifique las sinonimias y mapee las expresiones descriptivas hacia un inventario de ingredientes canónicos únicos. Este proceso no solo dota de coherencia al modelo de datos, sino que resulta matemáticamente crítico para asegurar la convergencia de los algoritmos de optimización combinatoria y la calidad de las recomendaciones finales [20].

3.2.1. Análisis Empírico de la Variabilidad en el Dataset Real

Para ilustrar la necesidad crítica de esta fase de normalización, se han categorizado las principales patologías de datos identificadas en el catálogo de recetas actual. Estas inconsistencias se dividen en cuatro dimensiones analíticas:

1. **Dispersión Léxica y Sinonimia Regional:** Este fenómeno ocurre cuando un mismo elemento o ingrediente biológico es referenciado mediante términos completamente distintos dentro del sistema. Esta variabilidad responde habitualmente al origen cultural de la receta, modismos lingüísticos locales o al criterio arbitrario del autor al registrar la entrada. La falta de un vocabulario controlado imposibilita el cruce directo de cadenas de texto con el inventario estandarizado del usuario.
2. **Contaminación por Comentarios Añadidos:** Esta patología se caracteriza por la intrusión de anotaciones subjetivas, aclaraciones sobre porciones o especificaciones del autor dentro de los campos que deberían albergar exclusivamente el nombre o la cantidad atómica del ingrediente. Este ruido semántico altera la estructura esperada por los algoritmos de extracción.
3. **Contaminación Procedimental (Texto Libre):** Secuencia en la que los campos destinados estrictamente a la declaración de elementos contienen metadatos relativos a técnicas culinarias, estados físicos intermedios o instrucciones de procesamiento que pertenecen lógicamente a la fase de preparación de la receta. Al introducir verbos y estados en variables de inventario, se rompe el comportamiento de los *parsers* estándar.
4. **Estructuras de Datos Colapsadas:** Se presenta cuando los límites de los tipos de datos no están correctamente definidos en el origen, provocando que metadatos estructurales (como títulos de subsecciones o agrupadores lógicos dentro de una receta) se almacenen e indexen de forma plana como si fuesen un ingrediente más. .

A continuación, la Figura 3.2 expone de manera unificada la distribución y ejemplos concretos de estas patologías extraídas directamente del dataset crudo.




Figura 3.2: Taxonomía de inconsistencias y representación lógica de ruido en el catálogo de ingredientes crudo.

Como se demuestra matemáticamente en la literatura de recuperación de información, mantener este nivel de entropía en el set de datos penaliza directamente el *recall* del sistema de recomendación. Sin una transformación que extraiga de forma unívoca el identificador conceptual, la cantidad física y la unidad estandarizada, cualquier consulta de optimización combinatoria sobre la nevera del usuario generará un porcentaje inaceptable de omisiones y errores.

3.2.2. Planteamiento Metodológico: Análisis Comparativo

El diseño experimental de este apartado se estructura bajo un enfoque comparativo que evalúa el rendimiento de dos paradigmas computacionales diferenciados para la resolución de la dispersión léxica: el procesamiento basado en reglas heurísticas deterministas frente al modelado mediante semántica vectorial fundamentado en Inteligencia Artificial.

La inclusión y análisis del método tradicional basado en reglas fijas responde a los siguientes criterios metodológicos dentro del desarrollo del proyecto:

1. **Establecimiento de una línea base (*Baseline*):** En el ámbito del procesamiento del lenguaje natural, la validación de un modelo predictivo avanzado requiere la definición previa de un estado de control o *baseline* algorítmico [21]. El pipeline heurístico (basado en expresiones regulares, remoción de diacríticos y diccionarios estáticos de exclusión) cumple esta función, proveyendo las métricas de referencia necesarias para cuantificar objetivamente la ganancia semántica de los modelos posteriores.
2. **Caracterización empírica del error:** La ejecución del enfoque tradicional actúa como un proceso de diagnóstico. El análisis estadístico de sus limitaciones inherentes (tales como los fenómenos de sobre-lematización o la incapacidad de indexar la variabilidad combinatoria del lenguaje libre) permite mapear y tipificar el ruido específico del corpus gastronómico.
3. **Evaluación del coste-beneficio computacional:** El despliegue de modelos de lenguaje basados en redes neuronales implica una mayor complejidad de implementación y un incremento en el consumo de recursos de cómputo. Disponer de los resultados del método heurístico permite realizar un análisis comparativo formal para determinar si el incremento en la complejidad tecnológica del sistema se traduce en una mejora proporcional en la unificación de las entidades.

De este modo, el flujo de trabajo adopta una estructura de investigación aplicada, donde cada fase matemática y computacional posterior se justifica a partir de las limitaciones cuantitativas detectadas en la etapa precedente.

3.2.3. Preprocesamiento Heurístico y Limpieza Basada en Reglas

Con el propósito de aislar la entidad central del ingrediente y mitigar la dispersión léxica, se diseñó e implementó un flujo de preprocesamiento secuencial basado en reglas heurísticas fijas. En el marco de la ingeniería de datos lingüísticos, este procedimiento se orientó a remover los elementos sintácticos y semánticos que acompañan al ingrediente pero no constituyen su núcleo identitario (tales como cuantificadores numéricos, adjetivos calificativos de estado o unidades de medida) [22]. De este modo, ante una cadena como "200 mililitros de leche caliente", el pipeline se programó para eliminar de forma determinista la subcadena "200 mililitros" del adjetivo "caliente", aislando el token "leche".

Este enfoque inicial basado en heurísticas deterministas se estructuró a través de cuatro fases de transformación secuencial:

1. **Normalización de codificación y remoción de diacríticos:** Dadas las discrepancias léxicas y las potenciales erratas ortográficas presentes en el lenguaje natural libre, se procedió a estandarizar el texto bajo el sistema de codificación ASCII plano. Utilizando la biblioteca *unicodedata*, se descompusieron los caracteres en sus componentes base para eliminar tildes, diéresis y transformar caracteres específicos del castellano (por ejemplo, la sustitución del grafema "ñ" por "n"), previniendo así la duplicidad de entidades por inconsistencias ortográficas.
2. **Lematización rudimentaria de plurales:** Con el fin de colapsar las variantes morfológicas de número (plural a singular), se programó un filtro de truncamiento basado en sufijos que eliminaba de forma sistemática la consonante final de cualquier palabra terminada en "s". Si bien esta regla redujo la variabilidad en sustantivos regulares, representó un enfoque con alta tasa de error por sobre-lematización (*overstemming*), al corromper términos singulares invariantes o de raíz terminada en dicha consonante [20].
3. **Filtrado de caracteres especiales mediante expresiones regulares:** Se implementó una máscara de filtrado mediante expresiones regulares (*RegEx*) encargada de restringir el alfabeto admisible. El subproceso purgó de forma estricta dígitos numéricos (enteros y fraccionarios), barras de división (/), operadores y símbolos de porcentaje, preservando de manera exclusiva los caracteres alfabéticos en minúscula (rango [a-z]) y los espacios en blanco para mantener la integridad de términos compuestos.
4. **Eliminación de *stop-words* de dominio gastronómico:** Para suprimir los cuantificadores y contenedores que no aportan valor semántico a la entidad del ingrediente, se confeccionó manualmente un diccionario de exclusión conceptual o *stop-words* especializado, adaptando el concepto tradicional de filtrado de palabras funcionales al dominio del proyecto [22]. Este listado incluyó unidades del sistema métrico y volumétrico tradicional y culinario, tales como "tazas", "gramos", "mililitros", "pizca", "cucharadas", "chorro".

Una vez ejecutado este *pipeline* sobre el total de registros, se procedió a realizar un análisis de agregación estadística para tabular el inventario de ingredientes resultantes y computar sus frecuencias absolutas de aparición dentro del corpus global.

3.2.4. Evaluación de Calidad y Análisis de Redundancia

La distribución de frecuencias de los ingredientes extraídos tras el filtrado manual reveló un comportamiento asimétrico característico de las distribuciones de lenguaje natural, gobernadas por leyes de potencia distributivas [23]. Con el propósito de evaluar formalmente

el rendimiento del preprocesamiento heurístico, se categorizó el inventario en dos subconjuntos en función de su representatividad estadística, definiendo como 'ingredientes de baja frecuencia' a aquellos con menos de 5 apariciones en la base de datos global.

Bajo una hipótesis analítica inicial, existe una alta probabilidad de que la mayoría de las cadenas ubicadas en este umbral de baja frecuencia no correspondan a ingredientes genuinamente exóticos, sino a fallos de segmentación provocados por el pipeline heurístico (cadenas que conservaron adjetivos o descriptores específicos debido a que no estaban contemplados en el diccionario de exclusión estático). No obstante, ante la posibilidad de que existieran ingredientes válidos pero poco comunes en el arte culinario, se descartó la eliminación directa del conjunto y se diseñó un algoritmo de validación por contención.

Este procedimiento consistió en verificar de forma automatizada si el texto de un ingrediente de baja frecuencia contenía de manera implícita una subcadena correspondiente a un ingrediente catalogado como común (alta frecuencia). Por ejemplo, si la cadena "huevos de corral frescos" (baja frecuencia) se evalúa frente al inventario, el sistema detecta que contiene el término indexado "huevos" (alta frecuencia). Al confirmarse la relación de contención, estas instancias de baja frecuencia pueden ser mapeadas y absorbidas por la entidad común, demostrando que representan una redundancia del sistema. Por el contrario, aquellas cadenas residuales de baja frecuencia que no presentaron ninguna coincidencia de contención fueron tipificadas como "ingredientes huérfanos", obligando a su preservación al no poder ser vinculadas analíticamente con otra entidad conocida.

Los resultados cuantitativos derivados de este estudio analítico se encuentran consolidados y distribuidos morfológicamente en la Figura 3.3.

```
Total ingredientes detectados: 15850
Total apariciones de ingredientes en recetas: 109541
Total ingredientes 'no comunes': 14128
Con coincidencia en 'comunes': 12080
Total 'huérfanos': 2048
- 'Huérfanos' que aparecen 1 VEZ: 1639
- 'Huérfanos' que aparecen 2 VECES: 246
- 'Huérfanos' que aparecen 3 VECES: 76
- 'Huérfanos' que aparecen 4 VECES: 87

Los 'huérfanos' representa el 12.92% de los ingredientes.
Los 'huérfanos' representa el 1.87% de las apariciones de los ingredientes.
```

Figura 3.3: Estudio de calidad y distribución taxonómica de los ingredientes tras la aplicación del pipeline de limpieza manual.

Al interpretar los datos métricos de la distribución se constatan dos fenómenos diferenciados:

Por un lado, la proporción de ingredientes de baja frecuencia que contienen un homólogo de alta frecuencia en su estructura textual es elevada, representando el **76,21 %** del total de entidades únicas remanentes. Este comportamiento corrobora las limitaciones del modelo heurístico: la confección manual de un diccionario estático de palabras de relleno resulta insuficiente para absorber la riqueza léxica, las permutaciones gramaticales y la combinatoria

semántica del lenguaje natural. Como consecuencia, el sistema presenta un problema de redundancia de datos, donde una misma entidad conceptual se encuentra fragmentada en múltiples variantes textuales no unificadas. Este escenario de solapamiento nominal queda ilustrado mediante los ejemplos expuestos en la Figura 3.4.

```
"mantequilla",  
"mantequilla",  
"mantequilla aceite",  
"mantequilla blanda",  
"mantequilla clarificada",  
"mantequilla derretida",  
"mantequilla engrasar molde",  
"mantequilla fria",  
"mantequilla fria en cubo",  
"mantequilla fria sin sal",  
"mantequilla fundida",  
"mantequilla mani",  
"mantequilla manteca",  
"mantequilla margarina",  
"mantequilla pomada",  
"mantequilla reblandecida",  
"mantequilla sin sal",  
"mantequilla sin sal derretida",  
"mantequilla sin sal fria en cubo",  
"mantequilla sin sal temperatura ambiente",  
"mantequilla temperatura ambiente",
```

Figura 3.4: Prueba empírica de redundancia en la detección de ingredientes por métodos heurísticos.

Por otro lado, se observa que el volumen de ruido semántico puro (ingredientes corruptos o sin sentido) es numéricamente acotado. Pese a que estas cadenas huérfanas constituyen una porción significativa del catálogo de términos únicos (**12,92 %**), su impacto real sobre la base de datos es marginal, afectando únicamente al **1,87 %** de las inserciones totales de ingredientes en las recetas del corpus.

En conclusión, los resultados demuestran de forma empírica que, si bien el preprocesamiento heurístico es efectivo para purgar el ruido estructural masivo y aislar la mayor parte de la carga volumétrica del *dataset*, no resuelve el problema de la redundancia semántica ni la unificación de entidades. Se evidencia, por lo tanto, la necesidad de trascender el enfoque algorítmico tradicional basado en reglas e implementar un modelo de normalización inteligente fundamentado en arquitecturas de espacios vectoriales latentes y semántica computacional.

3.2.5. Extracción cream y Normalización Semántica mediante Reconocimiento de Entidades Nombradas (NER)

Para superar las limitaciones inherentes en la técnica baseline, se planteó una alternativa basada en aprendizaje supervisado utilizando Reconocimiento de Entidades Nombradas (Na-

med Entity Recognition, NER). Esta tarea del procesamiento del lenguaje natural se especializa en la localización, delimitación y clasificación de secuencias textuales específicas (*spans*) dentro de un corpus libre, asignándolas a categorías conceptuales predefinidas [24]. En el contexto de este proyecto, el modelo NER se diseñó para aprender a aislar de forma adaptativa el núcleo nominal del ingrediente, ignorando los cuantificadores y modificadores contextuales sin necesidad de compilar diccionarios estáticos exhaustivos.

Para el desarrollo e implementación del modelo se utilizó la biblioteca de código abierto *spaCy* [25]. Específicamente, se seleccionó el modelo preentrenado *es_core_news_lg*, una arquitectura de gran escala optimizada para el idioma castellano que integra vectores de palabras y redes neuronales convolucionales (CNN) para capturar dependencias sintácticas y semánticas locales. Sobre este modelo base, se procedió a realizar un proceso de ajuste fino (*fine-tuning*) del componente especializado *ner*.

Due a la inexistencia de un corpus anotado específico para el dominio culinario de la plataforma origen, se construyó un conjunto de datos de entrenamiento nativo mediante la selección de muestras representativas extraídas de las recetas. El proceso de optimización del modelo se estructuró bajo una metodología iterativa de aprendizaje activo y curación del corpus, dividida en cuatro etapas consecutivas:

1. **Entrenamiento del sistema:** Alimentación del pipeline de *spaCy* con el conjunto de ejemplos anotados en formato de tuplas de compensación (*offsets*), actualización de los pesos de la red mediante descenso de gradiente.
2. **Inferencia y normalización:** Ejecución del modelo en fase de producción sobre el catálogo global de ingredientes para evaluar la capacidad de generalización del tokenizador semántico.
3. **Análisis de error:** Auditoría analítica de las salidas del modelo para identificar fallos sistemáticos de predicción, falsos positivos o delimitaciones incorrectas de los límites de la entidad.
4. **Ampliación y corrección del corpus:** Inserción estratégica de los casos de uso conflictivos corregidos manualmente dentro del conjunto de entrenamiento para mitigar el sesgo del modelo en la siguiente iteración.

Como resultado de esta optimización cíclica, se consolidó el inventario definitivo de ingredientes. Con el fin de evaluar el rendimiento de este enfoque bajo las mismas condiciones del estado de control, se replicó el análisis estadístico de distribución de frecuencias y validación por contención, cuyos hallazgos analíticos se exponen en la Figura 3.5.

Los datos derivados del análisis empírico demuestran que el problema de la redundancia léxica se redujo de manera significativa en comparación con el baseline heurístico. El volumen total de ingredientes únicos detectados en el catálogo experimentó una contracción del **72,87 %**, lo que confirma una alta capacidad de unificación conceptual. Asimismo, la proporción de ingredientes de baja frecuencia que contenían una entidad común remanente se contrajo en

```
Total ingredientes detectados: 4300
Total apariciones de ingredientes en recetas: 103233
Total ingredientes no comunes: 3291
Con coincidencia en comunes: 1852
Total huérfanos: 1439
- 'Huérfanos' que aparecen 1 VEZ: 944
- 'Huérfanos' que aparecen 2 VECES: 263
- 'Huérfanos' que aparecen 3 VECES: 139
- 'Huérfanos' que aparecen 4 VECES: 93

Los 'huérfanos' representa el 33.47% de los ingredientes.
Los 'huérfanos' representa el 1.39% de las apariciones de los ingredientes.
```

Figura 3.5: Estudio de calidad y distribución taxonómica de los ingredientes tras la optimización mediante el modelo NER.

una cantidad notable, evidenciando que el modelo NER logró aislar de forma efectiva el núcleo del token sin arrastrar adjetivos o modificadores contextuales.

En lo relativo al ruido semántico, si bien representa un porcentaje relativo superior dentro del catálogo de términos únicos debido a la drástica reducción de la redundancia, su impacto en la base de datos se mitigó, disminuyendo su frecuencia absoluta de aparición en el total de las recetas.

La Figura 3.6 contrasta visualmente la transición entre el espacio de datos generado por la primera normalización manual y el obtenido mediante el modelo NER, corroborando la capacidad de la arquitectura basada en aprendizaje estadístico para discriminar y extraer exclusivamente la información semánticamente útil.

```
"mantequilla",
"mantecquilla",
"mantecquilla de cacahuete",
"mantecquilla de mani",
"manzana",
```

Figura 3.6: Análisis comparativo de la dispersión léxica y resolución del problema de redundancia.

3.2.6. Ingeniería de Atributos y Homogeneización del Perfil de la Receta

Una vez resuelta la normalización de la entidad del ingrediente, se procedió a someter al resto de las variables de la receta a un flujo de ingeniería de atributos (*feature engineering*) e imputación de datos [26]. Este proceso es indispensable para transformar las estructuras de texto remanentes en vectores numéricos aptos para las operaciones matemáticas de los algoritmos de optimización.

- **Normalización temporal de la duración:** La información original indexada en formato de texto complejo (v.g., '2h 45m') se parseó mediante expresiones regulares y se transformó en una variable entera continua que expresa la duración absoluta en minutos mediante la relación lineal $(\text{horas} \times 60) + \text{minutos}$. Para resolver el problema de los datos faltantes (*missing values*) sin alterar la distribución general, se aplicó una técnica de **imputación por tendencia central**, asignando a los registros nulos la media aritmética calculada del corpus global [27]. Con el fin de validar el rigor de esta solución, en etapas posteriores del proyecto se analizará de forma empírica el impacto que tiene sobre el rendimiento y la convergencia de los algoritmos tanto la eliminación directa de los registros sin información como el uso de la citada media imputada.
- **Estructuración del perfil nutricional:** Los vectores macro-nutricionales (calorías, proteínas, grasas, carbohidratos y fibra) se purgaron de sufijos y unidades de medida (tales como "g." "gr") a través de un filtro de limpieza textual. Posteriormente, las subcadenas resultantes se convirtieron explícitamente a tipos de datos numéricos de coma flotante (*float*), posibilitando el planteamiento numérico de restricciones nutricionales en los casos de uso del recomendador.
- **Codificación ordinal de la dificultad:** El atributo categórico de complejidad técnica (bajo, medio, alto) se transformó mediante un mapeo ordinal discreto en una escala numérica cerrada [1, 3], donde el valor 1 representa la menor dificultad de ejecución.
- **Filtrado por consistencia de datos:** Como criterio de integridad de la base de datos, se ejecutó un proceso de depuración orientado a eliminar por completo aquellas recetas que carecían de un listado de ingredientes válido tras el scraping, al ser considerado un componente nulo no recuperable e imprescindible para el motor de búsqueda.
- **Vectorización e indexación maestra:** El flujo concluye con la transformación de la lista de ingredientes textuales de cada receta en un vector de identificadores enteros. Este proceso de indexación sustituye los strings por claves numéricas externas conectadas directamente con el ID único de la lista maestra de ingredientes canónicos, optimizando la velocidad de computación y el acceso a memoria durante las fases de optimización algorítmica.

Finalmente, con el propósito de garantizar la reproducibilidad de este estudio y fomentar los principios del código abierto (*Open Source*), los datos estructurados han sido depositados de forma pública en la plataforma GitHub. Específicamente, se ha puesto a disposición de la comunidad investigadora el conjunto de recetas tras su fase de limpieza y procesamiento, junto con el catálogo indexado de ingredientes y sus respectivos identificadores únicos. Este material queda accesible en abierto para su libre consulta, auditoría o reutilización en futuros proyectos de investigación¹.

¹Repositorio público disponible en: https://github.com/anaherrerozumarraga-hub/ontologia_culinaria

Modelado Semántico y Embeddings

La comparación tradicional de ingredientes mediante cadenas de caracteres o identificadores únicos estáticos presenta una limitación crítica en ingeniería de datos: la falta de densidad semántica. Desde la perspectiva de un sistema computacional básico, el ID asignado a 'aceite de oliva' y el asignado a 'aceite de girasol' son vectores ortogonales e independientes; el sistema carece de un mecanismo nativo para interpretar que ambas entidades comparten propiedades funcionales, estructurales y gastronómicas similares.

Para que los algoritmos de recomendación y optimización combinatoria operen con eficiencia, es indispensable reducir la esparcidad de las matrices de datos [20]. Los modelos de *embeddings* resuelven esta problemática mapeando cada ingrediente en un vector de números reales de baja dimensionalidad dentro de un espacio latente continuo.

El fundamento de este enfoque se basa en la *Hipótesis Distribucional*, que postula que las palabras que aparecen en contextos similares tienden a poseer significados afines [4]. Trasponiendo este principio al dominio culinario, aquellos ingredientes que coocurren sistemáticamente en las mismas combinaciones de recetas serán proyectados de forma adyacente en el espacio vectorial. De este modo, la afinidad culinaria se traduce en proximidad geométrica medible (v.g., similitud del coseno), permitiendo al sistema calcular sustituciones inteligentes u optimizar menús basándose en la compatibilidad latente de los alimentos.

4.1. Word2Vec: Contextualización, Implementación y Resultados

La primera arquitectura evaluada en este proyecto para la generación del espacio latente es *Word2Vec*, un modelo basado en redes neuronales de dos capas diseñado para aprender representaciones vectoriales densas a partir de las coocurrencias en un corpus de texto [5]. Este modelo destaca por su eficiencia computacional y por su capacidad para preservar relaciones analógicas lineales (fórmulas vectoriales del tipo $\vec{v}_{\text{rey}} - \vec{v}_{\text{hombre}} + \vec{v}_{\text{mujer}} \approx \vec{v}_{\text{reina}}$)

[6]. El framework permite el entrenamiento mediante dos aproximaciones metodológicas: *Continuous Bag-of-Words* (CBOW), que predice un token objetivo basándose en su contexto macro, y *Skip-gram*, que utiliza una palabra central para predecir el entorno circundante.

4.1.1. Estrategia de Modelado de Contexto Gastronómico

Para el entrenamiento del modelo con el corpus extraído, se determinó que limitar el contexto únicamente a la lista aislada de ingredientes reducía drásticamente la riqueza relacional del espacio latente. Por tanto, se diseñó una estrategia de extracción basada en el **Contexto Extendido de la Receta**. Por cada registro de la base de datos, se procedió a concatenar en una única secuencia textual tres bloques de información clave: el nombre de la receta, la lista de ingredientes normalizados por el modelo NER y el texto descriptivo de las instrucciones de elaboración.

El fundamento de este enfoque radica en capturar la sintaxis oculta de la preparación culinaria. Por ejemplo, si un ingrediente 'huevo' y otro 'azúcar' coocurren con frecuencia en recetas cuyos nombres o instrucciones contienen términos descriptivos como 'bizcocho', 'batir' o 'repostería', el algoritmo asimilará dicha correlación posicional dentro del mapa semántico, dotando al espacio geométrico de una dimensionalidad orientada a la afinidad de técnicas y menús.

Antes de alimentar la red neuronal, este contexto extendido se sometió a un pipeline de limpieza estandarizado que consistió en la conversión de todos los caracteres a minúsculas, la eliminación de elementos numéricos y caracteres especiales mediante expresiones regulares, la tokenización léxica y la remoción de palabras vacías (*stop-words*) genéricas del idioma castellano [22].

4.1.2. Parametrización e Hiperparámetros del Modelo

El modelo *Word2Vec* se configuró de forma específica para equilibrar el coste computacional con la estabilidad de las representaciones en el espacio latente. A continuación se justifican las variables de calibración seleccionadas [9]:

- **vector_size = 100**: Establece la dimensionalidad espacial intrínseca de los vectores densos. Un tamaño de 100 dimensiones es adecuado para el volumen del corpus analizado, previniendo problemas de sobreajuste (*overfitting*) que provocarían dimensiones superiores y reduciendo la esparcidad de las matrices de entrada para las fases de recomendación.
- **window = 5**: Define la distancia máxima entre el token objetivo y las palabras circundantes dentro del bucle de eventos del algoritmo. Una ventana intermedia asegura capturar tanto relaciones asociativas directas como la coocurrencia sectorial de ingredientes en una misma fase de la elaboración.
- **min_count = 1**: Restringe la exclusión de términos por baja frecuencia. Dado que los datos ya superaron un filtro estricto de normalización semántica mediante el modelo

NER, se retuvieron la totalidad de los tokens para asegurar cobertura volumétrica sobre los ingredientes residuales del catálogo.

- **workers = 4:** Parámetro de paralelización multihilo que optimiza el tiempo de convergencia aprovechando los núcleos del procesador.

4.1.3. Resolución de Frases Compuestas mediante Agregación Vectorial

Una particularidad del vocabulario resultante tras la fase NER es que ciertos términos canónicos no se componen de un token atómico único, sino de estructuras lingüísticas compuestas (frases complejas como 'aceite de oliva' o 'salsa de soja'). Dado que el modelo *Word2Vec* opera a nivel léxico individual (entrenando vectores independientes para 'aceite', 'oliva' o 'soja'), fue necesario diseñar un mecanismo de agregación algebraica para inferir el vector representativo de la frase completa.

Para resolver esta limitación, el sistema ejecuta un proceso de preprocesamiento específico para cada ingrediente del inventario maestro. Las cadenas se limpian de caracteres especiales, se tokenizan y se purgan de las *stop-words* de la misma forma en que se estructuró el corpus. Posteriormente, para cada término compuesto, el sistema itera sobre sus palabras constituyentes, verifica su existencia en el diccionario interno del modelo matemático y extrae sus vectores densos.

Análogamente a las técnicas clásicas de modelado de documentos mediante composición estática [28], si el término posee tokens válidos, se computa el **Vector Medio de la Frase** aplicando la operación matemática de la media aritmética generalizada:

$$\vec{v}_{\text{ingrediente}} = \frac{1}{N} \sum_{i=1}^N \vec{v}_{\text{token}_i}$$

Donde N representa el número de tokens válidos recuperados del término compuesto. Los vectores de ingredientes resultantes se almacenan en un mapa indexado estructurado, conformando una matriz continua lista para la computación analítica y su posterior evaluación de rendimiento.

4.1.4. Resultados y Validación Empírica del Espacio Latente

Para verificar que el espacio latente de 100 dimensiones ha asimilado correctamente tanto la afinidad culinaria como la incompatibilidad de dominio, se diseñó una prueba de validación basada en la métrica de **Similitud del Coseno**. Matemáticamente, la relación angular entre dos ingredientes dentro del espacio continuo se determina mediante el cálculo de [7]:

$$\text{Similitud}_{\text{coseno}}(\vec{u}, \vec{v}) = \frac{\vec{u} \cdot \vec{v}}{\|\vec{u}\| \|\vec{v}\|}$$

Donde un valor próximo a 1 denota que los vectores apuntan en direcciones prácticamente idénticas (máxima coocurrencia y afinidad), mientras que un valor cercano a 0 o netamente negativo indica ortogonalidad o separación angular dentro del espacio latente.

Con el objetivo de demostrar empíricamente que el modelo aproxima geométricamente los elementos similares y aleja los inconexos, se seleccionó un conjunto de control compuesto por seis ingredientes de tres dominios gastronómicos diferenciados (dulces, bases saladas y proteínas marinas) y se computó la matriz de similitud cruzada real empleando el modelo entrenado. Los resultados numéricos se consolidan en la Tabla 4.1.

Ingrediente	Chocolate	Azucar	Ajo	Cebolla	Merluza	Gamba
Chocolate	1.000	0.157	-0.128	-0.136	-0.211	-0.048
Azucar	0.157	1.000	0.215	0.163	0.036	0.085
Ajo	-0.128	0.215	1.000	0.492	0.134	0.107
Cebolla	-0.136	0.163	0.492	1.000	0.192	0.243
Merluza	-0.211	0.036	0.134	0.192	1.000	0.659
Gamba	-0.048	0.085	0.107	0.243	0.659	1.000

Tabla 4.1: Matriz cruzada de similitud del coseno para la validación de cohesión y separación del espacio vectorial en Word2Vec.

Al analizar los coeficientes reales extraídos del modelo en la Tabla 4.1, se observan con claridad los dos fenómenos geométricos que validan la distribución semántica del espacio latente:

1. **Cohesión interna por afinidad culinaria:** Los ingredientes que comparten contextos de preparación o que combinan habitualmente en la gastronomía exhiben coeficientes de similitud marcadamente positivos. Este comportamiento es evidente en el bloque marino al analizar la intersección *Merluza-Gamba* (0,659), lo que refleja su constante co-ocurrencia en platos de cazuela, arroces o caldos. Asimismo, los componentes esenciales del sofrito tradicional, *Ajo-Cebolla*, muestran una sólida cercanía geométrica (0,492).

Por otra parte, el bloque dulce se comporta de manera coherente: el *Azucar* y el *Chocolate* presentan una correlación positiva (0,157). Resulta de especial interés analítico observar cómo el *Azucar* mantiene una relación moderadamente positiva con el *Ajo* (0,215) y la *Cebolla* (0,163); esto responde fielmente a la naturaleza del corpus culinario, donde el azúcar interviene de forma recurrente en preparaciones saladas para corregir la acidez de salsas o en procesos de caramelización de hortalizas.

2. **Separación y divergencia inter-dominio:** Las entidades cuyos contextos de aplicación son mutuamente excluyentes o dispares son proyectadas en direcciones opuestas dentro del espacio de 100 dimensiones, arrojando valores negativos u ortogonales próximos a cero. Esto se constata analizando el comportamiento del vector del *Chocolate*, el cual se distancia drásticamente de los bloques salados y marinos, obteniendo valores negativos al cruzarse con el *Ajo* (-0,128), la *Cebolla* (-0,136) y, de manera más acusada, con la

Merluza ($-0,211$). De igual forma, la afinidad entre el *Azucar* y la *Merluza* cae a un valor prácticamente ortogonal ($0,036$), reflejando la nula interacción de ambos elementos en el recetario general.

Estos resultados demuestran de forma empírica que el modelo *Word2Vec* entrenado mediante el contexto extendido de la receta posee la sensibilidad matemática necesaria para estructurar el conocimiento gastronómico sin supervisión humana. La geometría del espacio continuo es consistente con la realidad: aproxima los ingredientes que interactúan armónicamente en los flujos de preparación y segrega aquellos que pertenecen a mundos culinarios incompatibles, garantizando una base robusta para las operaciones algorítmicas del recomendador.

4.2. FastText: Contextualización, Implementación y Resultados

Como contraparte experimental e incremental frente al modelo previo, se procedió al despliegue de *FastText*, una arquitectura de código abierto desarrollada por *Facebook AI Research* que evoluciona los principios estáticos de *Word2Vec* [29]. La innovación crítica de esta tecnología radica en la introducción de información morfológica interna mediante el análisis a nivel de sub-palabra (*subword information*).

A diferencia de los enfoques tradicionales que mapean cada término como una entidad atómica y cerrada en un diccionario estático, *FastText* descompone internamente cada palabra en una serie consecutiva de n -gramas de caracteres. El vector final de un token se computa mediante la suma algebraica y normalizada de las representaciones vectoriales de las subcadenas que lo constituyen.

Esta particularidad algorítmica es de especial interés para el dominio culinario debido a su robustez ante variantes morfológicas o sufijos frecuentes, su captura nativa de raíces semánticas compartidas y, fundamentalmente, la mitigación del problema de vocabulario desconocido al permitir inferir vectores aproximados para términos no vistos en la fase de entrenamiento a partir de sus n -gramas constituyentes.

4.2.1. Parametrización e Hiperparámetros del Modelo

Para asegurar la homogeneidad experimental y permitir un contraste posterior válido, el modelo *FastText* se alimentó con el mismo corpus textual estructurado bajo el enfoque de contexto extendido (coocurrencia de nombres de recetas, ingredientes NER e instrucciones de elaboración). El pipeline se configuró de modo no supervisado bajo la API nativa de la biblioteca.

La calibración del algoritmo no supervisado se definió mediante variables de control orientadas a homogeneizar las dimensiones espaciales con el modelo base y asegurar una convergencia profunda del gradiente. Los hiperparámetros se justifican a continuación [29]:

- **Modelo base (*model* = 'skipgram')**: Se seleccionó la arquitectura basada en la predicción del entorno contextual a partir del token central. Al igual que en *Word2Vec*, este enfoque incrementa la calidad semántica al operar sobre dominios altamente especializados y de vocabulario restringido.
- **Dimensionalidad espacial (*dim* = 100)**: Se fijó el tamaño intrínseco del vector latente en 100 dimensiones continuas de números reales. Mantener este valor idéntico al de la sección previa es un requisito de ingeniería indispensable para garantizar una comparación directa y justa de rendimiento en las fases de análisis.
- **Ventana de contexto (*ws* = 5)**: Define el radio máximo de escaneo del operador para evaluar las coocurrencias de tokens en el corpus extendido.
- **Frecuencia mínima (*minCount* = 1)**: Al basar su aprendizaje en n-gramas de caracteres, el modelo es capaz de estabilizar variables con pocas ocurrencias. Mantener el límite en uno asegura una cobertura absoluta del inventario culinario.
- **Épocas de entrenamiento (*epoch* = 10)**: Determina el número de iteraciones completas sobre la totalidad del corpus. Se duplicaron los ciclos frente al estándar con el fin de optimizar el ajuste de los pesos de la red sobre las subcadenas morfológicas del castellano.
- **Procesamiento paralelo (*thread* = 4)**: Asignación de hilos de cómputo concurrentes para acelerar la velocidad de entrenamiento en el entorno de desarrollo.

4.2.2. Resolución de Frases Compuestas mediante Agregación Vectorial

Dado que el catálogo consolidado por el extractor NER presenta abundantes nombres compuestos de ingredientes ('salsa de soja', 'aceite de girasol') y que las consultas vectoriales se realizan token por token, se aplicó la misma metodología de unificación algebraica diseñada para el modelo estático.

Para cada frase compleja indexada, se extrajeron los vectores densos de sus términos válidos. En caso de contar con una secuencia de floats coherente, se computó el **Vector Medio de la Frase** mediante la media aritmética de la distribución multidimensional:

$$\vec{v}_{\text{ingrediente_ft}} = \frac{1}{N} \sum_{i=1}^N \vec{v}_{\text{token}_i}$$

Donde N es el volumen de sub-vectores de palabras válidas extraídos por la función nativa de *FastText*. El resultado de esta operación geométrica se indexó en la estructura cartográfica continua, consolidando la matriz de entrada final para el análisis comparativo del recomendador.

4.2.3. Resultados y Validación de Cohesión Espacial

La validación del mapa continuo de *FastText* se ejecutó bajo la misma métrica matemática de la similitud del coseno utilizada previamente, garantizando la consistencia analítica de la memoria. Con el propósito de comprobar la reordenación del espacio al incorporar n-gramas de caracteres, se enfrentó al mismo conjunto de control cruzado de seis ingredientes (bloque dulce, condimentos y proteínas marinas). Los coeficientes reales devueltos por la arquitectura se muestran en la Tabla 4.2.

Ingrediente	Chocolate	Azucar	Ajo	Cebolla	Merluza	Gamba
Chocolate	1.000	0.458	0.175	0.180	0.231	0.220
Azucar	0.458	1.000	0.480	0.429	0.176	0.167
Ajo	0.175	0.480	1.000	0.881	0.419	0.471
Cebolla	0.180	0.429	0.881	1.000	0.395	0.440
Merluza	0.231	0.176	0.419	0.395	1.000	0.522
Gamba	0.220	0.167	0.471	0.440	0.522	1.000

Tabla 4.2: Matriz cruzada de similitud del coseno para la validación de cohesión y separación del espacio vectorial en FastText.

Al examinar los coeficientes de la Tabla 4.2, se evidencia un cambio estructural definitivo en la morfología del espacio geométrico respecto al modelo previo. El comportamiento de las distancias se analiza bajo los siguientes ejes técnicos:

1. **Incremento global de la densidad del espacio:** A diferencia de la naturaleza discreta del modelo atómico anterior, los coeficientes de *FastText* se desplazan hacia valores netamente positivos, eliminando las distancias negativas. Este fenómeno es intrínseco a las arquitecturas basadas en información de sub-palabras: al proyectar n-gramas de caracteres compartidos dentro de las cadenas textuales del corpus culinario, se establece un umbral base de similitud morfológica y sintáctica generalizada que densifica el espacio continuo [29].
2. **Maximización de la cohesión en clústeres culinarios:** Las afinidades directas entre ingredientes fuertemente acoplados en el recetario experimentan una contracción geométrica muy acusada. La intersección *Ajo-Cebolla* se eleva hasta un coeficiente de 0,881, consolidando un núcleo vectorial altamente cohesionado para las bases de sofrito. De igual forma, el bloque marino (*Merluza-Gamba* con 0,522) y el bloque de repostería (*Chocolate-Azucar* con 0,458) ratifican que el modelo localiza y agrupa los elementos semánticamente compatibles con gran solidez.
3. **Atracción contextual transversal:** Se observa que el *Azucar* incrementa su proximidad con el *Ajo* (0,480) y la *Cebolla* (0,429). Al evaluar subcadenas morfológicas recurrentes asociadas a los procesos de cocción compartidos en las instrucciones del corpus (como terminaciones de verbos de acción culinaria o adjetivaciones estructurales), los n-gramas

asimilan interacciones colaterales que escapan a los diccionarios estáticos, dotando al espacio de una gran sensibilidad hacia las coocurrencias macro de la base de datos.

Estos resultados validan la convergencia del entrenamiento de *FastText* empleando el enfoque sub-palabra. La arquitectura mitiga la ortogonalidad matemática original del texto y genera representaciones robustas donde la cercanía léxica y contextual se unifican de forma continua, aportando propiedades de regularización que serán analizadas comparativamente en el siguiente apartado.

4.3. Comparación y Análisis de Resultados

Una vez obtenidos y validados de forma independiente los espacios latentes generados por las arquitecturas *Word2Vec* y *FastText*, se procedió a realizar un análisis comparativo estructurado. El objetivo de este contraste es evaluar cómo la naturaleza algorítmica de cada modelo (mapeo atómico de tokens frente a descomposición morfológica en sub-palabras) afecta a la topología del espacio continuo y determinar cuál de las soluciones proporciona el entorno geométrico óptimo para el motor de recomendación.

4.3.1. Divergencias Estructurales en la Topología del Espacio

Al contrastar cuantitativamente las matrices de similitud cruzada extraídas (Tabla 4.1 y Tabla 4.2), se evidencia un cambio radical en la distribución y el comportamiento de las distancias vectoriales:

- **Dinámica de separación inter-dominio:** El modelo *Word2Vec* exhibe una capacidad de segregación marcadamente superior para delimitar las fronteras de contextos culinarios incompatibles. Esto se comprueba al analizar el vector del *Chocolate*, el cual arroja correlaciones netamente negativas o próximas a cero absoluto contra el bloque salado (*Ajo*: -0,128, *Cebolla*: -0,136) y el bloque marino (*Merluza*: -0,211).

En contraposición, *FastText* tiende a colapsar el espacio hacia valores globales netamente positivos, elevando la similitud del *Chocolate* frente al *Ajo* a 0,175 y frente a la *Merluza* a 0,231. Este fenómeno demuestra que el análisis de n-gramas de caracteres introduce un sesgo de proximidad sintáctica e idiomática estructural que difumina el límite de los dominios mutuamente excluyentes, restando capacidad al sistema para identificar combinaciones de ingredientes altamente disonantes.

- **Dinámica de cohesión contextual interna:** En lo relativo a la agrupación de elementos con un alto acoplamiento funcional en las recetas, ambas arquitecturas demuestran un rendimiento excelente, pero bajo mecánicas diferentes. El binomio fundamental del sofrito, *Ajo-Cebolla*, alcanza una similitud de 0,492 en *Word2Vec* y se dispara hasta 0,881 en *FastText*.

Esta hiper-cohesión en *FastText* es el resultado directo de la coincidencia morfológica y la redundancia de subcadenas léxicas en castellano asociadas a dichos términos

dentro de los mismos bloques de instrucciones del corpus. Sin embargo, en el bloque proteico marino (*Merluza-Gamba*), donde los tokens no comparten ninguna raíz léxica o morfológica obvia, *Word2Vec* computa una similitud superior (0,659) frente a *FastText* (0,522). Esto evidencia que el modelo atómico captura con mayor pureza la coocurrencia semántica real basada estrictamente en el contexto extendido de la receta, sin verse distorsionado por similitudes superficiales de caracteres.

4.3.2. Impacto de la Información Sub-palabra (*Subword Information*)

El análisis comparativo confirma que la inyección de n-gramas de caracteres en *FastText* actúa como un regularizador matemático agresivo [29]. Si bien esta propiedad dota al sistema de una robustez matemática absoluta ante errores ortográficos, variantes léxicas y tokens fuera de vocabulario (*Out-Of-Vocabulary*, OOV) —ventaja crítica en entornos de producción con datos de usuario ruidosos—, tiene como contrapartida un coste de resolución semántica.

Al evaluar las relaciones transversales, se observa que *FastText* eleva la similitud del *Azucar* con el *Ajo* (0,480) y la *Cebolla* (0,429) a niveles prácticamente idénticos a los de un clúster culinario directo. Aunque existe una justificación culinaria para cierta cercanía debido a los procesos de corrección de acidez y caramelización, un coeficiente tan elevado reduce la distancia relativa entre ingredientes de naturaleza opuesta. Esto sugiere que el exceso de peso otorgado a los n-gramas provoca que el modelo asimile estructuras de redacción comunes del corpus (tales como la sintaxis de las instrucciones o las métricas de peso) por encima de la afinidad culinaria real de las entidades.

4.3.3. Selección de la Arquitectura Óptima para el Recomendador

Para formalizar la elección de la arquitectura definitiva, se evaluaron los modelos en función de tres criterios de ingeniería de software alineados con los objetivos del proyecto: **capacidad de discriminación**, **fidelidad al dominio** y **estabilidad matricial**. La evaluación cualitativa se sintetiza en la Tabla 4.3.

Criterio de Evaluación	Word2Vec	FastText
Segregación de dominios opuestos	Alta (Eficiente)	Baja (Sesgo positivo)
Cohesión de afinidad culinaria	Alta (Semántica pura)	Alta (Morfosemántica)
Robustez ante ruido textual y OOV	Baja (Sensible a tokens)	Absoluta (Por n-gramas)
Resolución de sustituciones de ingredientes	Óptima (Por contexto)	Subóptima (Por raíz léxica)

Tabla 4.3: Matriz de decisión técnica para la selección del modelo de embeddings definitivo.

A la luz de los datos analizados en la Tabla 4.3, se determina que **Word2Vec constituye la solución óptima para actuar como núcleo del motor de recomendación**. Su geometría espacial preserva con mayor fidelidad la ortogonalidad de los mundos culinarios distantes (evitando proponer combinaciones aberrantes como chocolate con pescado) y basa la cercanía geométrica estrictamente en la compatibilidad de uso culinario y no en la similitud ortográfica de los strings.

No obstante, dada la innegable ventaja operativa de *FastText* para resolver cadenas de texto desconocidas introducidas por usuarios en fases dinámicas, se establece como criterio de diseño utilizar el espacio vectorial de *Word2Vec* como el calculador maestro de similitud para los algoritmos de optimización de menús, reservando la lógica sub-palabra de *FastText* como un subsistema secundario de contingencia para la normalización en tiempo real de términos huérfanos.

4.3.4. Validación Topológica mediante Agrupamiento Jerárquico (Dendrograma)

Con el propósito de expandir la validación del espacio latente y demostrar que el modelo *Word2Vec* es capaz de estructurar relaciones semánticas complejas a gran escala, se extrajo un subconjunto compuesto por los 50 ingredientes más frecuentes del corpus. Al estar el archivo de vectores ordenado de manera nativa por frecuencia de aparición, estos elementos representan el núcleo operativo del dominio gastronómico indexado.

Sobre las representaciones vectoriales de estos 50 ingredientes se aplicó un algoritmo de agrupamiento jerárquico aglomerativo [20]. Como métrica de disimilitud se empleó la distancia del coseno ($1 - \text{Similitud}_{\text{coseno}}$) y como criterio de asignación el método de vinculación completa (*complete linkage*). La proyección geométrica resultante se consolida en el dendrograma de la Figura 4.1.

La topología del árbol de la Figura 4.1 corrobora de forma empírica que el espacio continuo de 100 dimensiones ha segregado el conocimiento culinario en macro-clústeres funcionales disjuntos de alta coherencia, sin necesidad de supervisión o etiquetado manual previo:

- **Estructura de Bloques Homogéneos:** El algoritmo aísla con nitidez el entorno de repostería y panificación (visible en los bloques central e intermedio), donde ingredientes como *Canela*, *Esencia de vainilla*, *Vainilla*, *Mantequilla*, *Manteca*, *Levadura* y las variantes de *Harina* convergen bajo una misma raíz comunal, alejados por completo de los entornos salados.
- **Fusión de Variantes Morfológicas:** Se demuestra la robustez del embedding ante la flexión gramatical. Parejas léxicas como *Cebolla* - *Cebollas*, *Pimiento* - *Pimiento rojo* o *Pimienta* - *Pimienta negra* se fusionan en los umbrales de distancia más bajos de sus respectivas ramas, probando que el modelo captura la identidad conceptual de los alimentos por encima de su ortografía.
- **Consolidación de Bases y Proteínas:** En la sección inferior emerge con fuerza el núcleo de la cocina mediterránea (*Aceite*, *Aceite de oliva*, *Ajo*, *Cebolla*), mientras que en ramas adyacentes se delimitan componentes proteicos limpios (*Carne* y *Pollo*) frente a hortalizas aromáticas de cocción (*Perejil*, *Cilantro*, *Laurel*, *Tomillo*).

Esta estructuración espontánea del mapa de ingredientes valida definitivamente la calidad del modelo vectorizado. El espacio latente no solo es métricamente preciso en distancias

cortas, sino que posee una macro-estructura topológica global robusta y fiel a la lógica del dominio gastronómico, garantizando la fiabilidad de las operaciones algebraicas continuas que se ejecutarán en los casos de uso posteriores.

4. MODELADO SEMÁNTICO Y EMBEDDINGS




Figura 4.1: Dendrograma de agrupamiento jerárquico basado en la distancia del coseno para el top 50 ingredientes más comunes.

Experimentación de metaheurísticas

5.1. Optimización monobjetivo y cobertura semántica en el espacio latente

El primer escenario operativo se centra de manera exclusiva en la maximización del solapamiento o *overlap* entre los ingredientes disponibles en el inventario del usuario y los requerimientos lógicos de las recetas indexadas. El propósito de este enfoque es identificar aquellas preparaciones culinarias que minimicen la necesidad de adquirir nuevos alimentos.

5.1.1. Algoritmo Baseline: Coincidencia Determinista de Conjuntos

Para establecer un marco de referencia comparativo y evaluar el impacto real de los espacios vectoriales, se diseñó e implementó un algoritmo *baseline* de carácter determinista. Esta solución aborda el problema de la recomendación desde una perspectiva booleana y discreta, abstrayéndose por completo de cualquier representación continua o conocimiento semántico del dominio gastronómico.

El funcionamiento del algoritmo se fundamenta en la teoría de conjuntos y opera directamente sobre los identificadores numéricos únicos (*IDs*) asignados a cada ingrediente en el inventario maestro de referencia. El proceso formalizado sigue la siguiente secuencia lógica:

1. **Modelado del inventario y recetas:** El inventario de ingredientes proporcionado por el usuario (I) y la lista de ingredientes requeridos por una receta específica (R) se transforman internamente en conjuntos finitos de identificadores numéricos disjuntos:

$$I = \{idx_1, idx_2, \dots, idx_m\}$$

$$R = \{idx_1, idx_2, \dots, idx_k\}$$

2. **Cálculo del Score de Coincidencia (Intersección):** El sistema itera sobre la totalidad de la base de datos de recetas evaluando la intersección matemática entre el conjunto del inventario del usuario y el de la receta. La métrica primaria de puntuación (*Score*) equivale al cardinal de dicha intersección, representando el número absoluto de coincidencias exactas:

$$\text{Score}(I, R) = |I \cap R|$$

3. **Cálculo de Proporción Coaxial:** En aquellos casos donde el *Score* es estrictamente superior a cero, se calcula una métrica secundaria de normalización denominada proporción de cobertura. Esta variable mide qué fracción del total de ingredientes que exige la receta está cubierta por el inventario del usuario, actuando como un factor de desempate de eficiencia:

$$\text{Proporción}(I, R) = \frac{|I \cap R|}{|R|}$$

4. **Ordenación y Selección Multicriterio:** Finalmente, el sistema consolida las recetas candidatas y aplica un criterio de ordenación léxico-gráfico descendente. La ordenación prioriza en primera instancia el *Score* absoluto de coincidencias y, ante empates en dicha métrica, evalúa la máxima *Proporción*. El algoritmo extrae el *top-N* de recetas con mayor puntuación para conformar la recomendación final.

5.1.1.1. Limitaciones Estructurales del Enfoque Baseline

Aunque este algoritmo exhibe una excelente eficiencia computacional al basarse en operaciones de búsqueda en tablas *hash* y conjuntos de costo temporal constante $\mathcal{O}(1)$, presenta severas limitaciones de diseño debido a su rigidez lógica:

- **Vulnerabilidad ante la Sinonimia y Variación Léxica:** Al depender de un identificador numérico rígido asociado a una cadena de texto exacta, el algoritmo es incapaz de identificar equivalencias semánticas elementales.
- **Sesgo de Escala e Invariabilidad:** El ordenamiento basado estrictamente en el conteo absoluto de palabras idénticas tiende a sobre-recomendar recetas masivas o complejas con listas de ingredientes muy extensas, reduciendo drásticamente la variabilidad de las recomendaciones y la capacidad de sugerir platos alternativos o creativos a partir de un inventario acotado.

5.1.1.2. Resultados y Análisis Empírico del Enfoque Baseline

Para evaluar el comportamiento del algoritmo determinista, se alimentó el sistema con un escenario de prueba cerrado basado en un inventario doméstico real. Este inventario de control está constituido por los identificadores correspondientes a 46 ingredientes comunes y

variados que reflejan fielmente el contenido de una despensa heterogénea, abarcando desde condimentos y grasas base hasta proteínas, hortalizas, carbohidratos y elementos de repostería o salsas especializadas (v.g., *sal*, *aceite*, *pechuga de pollo*, *lechuga*, *arroz*, *ajo*, *cebolla*, *salsa de soja*, *sriracha*, *chocolate* y *azúcar*). Las cinco recomendaciones con mayor índice de solapamiento absoluto extraídas por este módulo base bajo estas condiciones de contorno se consolidan en la *Tabla 4*.

Receta Recomendada	Puntuación (Escalar)
Receta de Albóndigas con salsa agri dulce	10
Receta de Pavo relleno con arroz salvaje	10
Receta de Croquetas de pechuga de pollo caseras	9
Receta de Garbanzos con espinacas y huevo duro	9
Receta de Albóndigas de soja texturizada	9

Tabla 5.1: Resultados de recomendación del algoritmo Baseline mediante optimización exacta de overlap.

El análisis cualitativo de las métricas reales expuestas en la *Tabla 4* corrobora de forma empírica las deficiencias estructurales de los modelos basados en lógica discreta de conjuntos cuando se enfrentan a la flexibilidad semántica del lenguaje:

1. **Rigidez absoluta ante la variación léxica y sinonimia:** Al operar sobre un acoplamiento rígido de identificadores únicos, el sistema exige una coincidencia de caracteres exacta.
2. **Sesgo por volumen de coincidencias brutas:** El algoritmo sufre un problema estructural al priorizar de manera desproporcionada aquellas recetas que poseen listas extensas de ingredientes. Debido a que el operador binario acumula un punto por cada acierto individual, un plato con un número elevado de componentes tiende a posicionarse en los primeros puestos del *top-N* simplemente por probabilidad matemática de solapamiento. Esto provoca que el sistema recomiende recetas complejas en las que el usuario sí coincide en muchos elementos, pero ignora el hecho crítico de que sigue sin tener la receta completa para poder cocinarla.
3. **Restricción de la variabilidad por ausencia de sustitución:** El requerimiento de identidad matemática exacta ($|I \cap R|$) descarta por completo recetas que podrían ser cocinadas realizando sustituciones lógicas inmediatas (como intercambiar un caldo de verduras por uno de pollo, o cebollín por cebolla). Este comportamiento penaliza la variabilidad del recomendador, limitando la diversidad de platos alternativos que el motor es capaz de sugerir a partir de un mismo conjunto cerrado de ingredientes disponibles.

Estos resultados demuestran que la maximización del *overlap* mediante emparejamiento exacto resulta insuficiente para dotar al recomendador de una experiencia dinámica. La

ausencia de una métrica de distancia continua impide al sistema reconocer similitudes entre términos formalmente distintos pero conceptualmente cercanos, lo que justifica la transición hacia operadores de álgebra lineal basados en espacios vectoriales latentes para resolver el solapamiento desde una perspectiva continua.

5.1.2. Algoritmo de Búsqueda Local Estocástica (Random Local Search)

Para superar las severas restricciones impuestas por el enfoque determinista de conjuntos (*Baseline*), se diseñó e implementó un motor de optimización metaheurístico basado en el algoritmo de Búsqueda Local Estocástica (*Random Local Search*) [13]. Este módulo reconfigura por completo el problema del solapamiento de ingredientes, abandonando la lógica discreta binaria en favor de un espacio de optimización continuo guiado por la proximidad geométrica de los embeddings de *Word2Vec* [5].

El algoritmo asume que el inventario del usuario y las recetas de la base de datos habitan en un entorno semántico flexible, donde la ausencia de un ingrediente exacto no invalida la viabilidad de un plato si la despensa dispone de un sustituto funcionalmente análogo en el espacio latente.

5.1.2.1. Operador de Sustitución Semántica Continua

El núcleo de este optimizador radica en su capacidad para evaluar dinámicamente la compatibilidad de ingredientes en tiempo de ejecución. Dado un ingrediente requerido por la receta $i_r \notin I$ (donde I es el inventario del usuario), el sistema no computa una coincidencia nula, sino que realiza una búsqueda exhaustiva sobre todos los ingredientes disponibles en la despensa del usuario para inferir el grado de reemplazo más alto posible.

Matemáticamente, el operador de sustitución se define como una función adaptativa basada en la similitud del coseno [30, 7]:

$$S(i_r, I) = \begin{cases} 1,0 & \text{si } i_r \in I \\ \max_{j \in I} (\text{Sim}_{\cos}(V(i_r), V(j))) & \text{si } \max_{j \in I} (\text{Sim}_{\cos}(V(i_r), V(j))) \geq \gamma \\ 0,0 & \text{en otro caso} \end{cases}$$

Donde $V(\cdot) \in \mathbb{R}^{100}$ representa la proyección del ingrediente en el espacio vectorial latente de *Word2Vec* y γ constituye un hiperparámetro crítico denominado **Umbral de Sustitución**. Si la máxima afinidad angular entre el ingrediente ausente y algún elemento de la despensa supera dicho umbral, el algoritmo acepta el reemplazo y adopta el valor continuo de la similitud como la puntuación parcial de solapamiento, indexando de forma interna qué ingrediente sustituye a cuál. Esta estrategia de filtrado semántico estricto mediante umbrales adaptativos permite mitigar el ruido derivado de relaciones vectoriales espurias en espacios latentes de baja dimensionalidad [9].

5.1.2.2. Formalización de la Función Objetivo (Fitness Function)

A diferencia del conteo absoluto de elementos de la intersección discreta, la función de aptitud (*fitness function*) de este algoritmo evalúa la calidad del solapamiento semántico de manera ponderada y normalizada, aplicando además restricciones duras y penalizaciones lineales:

1. **Cómputo de Cobertura Base (C):** Se calcula el sumatorio de las puntuaciones de coincidencia o sustitución para todos los ingredientes exigidos por la receta, normalizándose según la longitud de esta para evitar el sesgo de saturación por tamaño:

$$C = \frac{\sum_{k \in R} S(k, I)}{|R|}$$

2. **Restricción Hard de Viabilidad (*Hard Constraint*):** Se introduce el hiperparámetro $M_{\max}$ que define el límite máximo de ingredientes completamente ausentes (aquellos cuya puntuación de sustitución es 0,0) que el usuario puede tolerar. Si una receta excede esta restricción ($\text{count}(S = 0) > M_{\max}$), la función objetivo colapsa inmediatamente devolviendo una aptitud nula (0,0), descartando el plato de forma fulminante.
3. **Penalización Lineal de Solapamiento:** Para castigar la necesidad de compra de ingredientes críticos no sustituibles, el score de cobertura se penaliza linealmente en función del número de elementos faltantes absolutos (N_f) mediante un coeficiente de penalización β :

$$\text{Score}_{\text{final}} = \max(0, 0, C - (N_f \cdot \beta))$$

5.1.2.3. Mecánica de Exploración del Espacio de Soluciones

Al tratarse de una heurística estocástica de vecindario global, el algoritmo no requiere recorrer de forma secuencial ni exhaustiva las miles de recetas del corpus en cada iteración. Su flujo operativo se estructura en las siguientes fases:

1. **Inicialización:** Se selecciona de forma completamente aleatoria una receta del corpus (R_{actual}) y se calcula su aptitud inicial mediante la función objetivo: $\text{Score}_{\text{actual}} = f(R_{\text{actual}}, I)$.
2. **Exploración Estocástica del Vecindario:** En cada iteración t hasta un máximo prefijado $T_{\max}$, el algoritmo selecciona una receta vecina ($R_{\text{candidata}}$) mediante muestreo aleatorio uniforme sobre el espacio total de recetas y evalúa su aptitud: $\text{Score}_{\text{candidata}} = f(R_{\text{candidata}}, I)$.
3. **Criterio de Aceptación Monótono:** Se aplica un criterio de ascenso estricto. La receta candidata reemplaza al estado actual si y solo si demuestra una mejora estricta en la optimización del solapamiento semántico:

$$\text{Si } \text{Score}_{\text{candidata}} > \text{Score}_{\text{actual}} \implies R_{\text{actual}} = R_{\text{candidata}}$$

En caso contrario, la solución candidata es rechazada y el sistema mantiene su explotación sobre el óptimo local transitorio.

Este enfoque mitiga el coste computacional clásico de las búsquedas combinatorias y dota al sistema de una enorme flexibilidad. Al delegar la lógica en la distancia del coseno, el recomendador es capaz de saltarse las barreras ortográficas y descubrir recetas viables mediante combinaciones gastronómicas análogas imposibles de detectar por el algoritmo de emparejamiento estricto.

5.1.2.4. Evaluación de Resultados y Análisis de Hiperparámetros

En esta sección se exponen y discuten los resultados empíricos derivados de la ejecución del algoritmo de Búsqueda Local Estocástica (*Random Local Search*) enfocado en la optimización del solapamiento semántico continuo. Para realizar un análisis de sensibilidad riguroso, el optimizador fue sometido a ocho configuraciones distintas de su espacio de control tri-dimensional, definido por el Umbral de Sustitución (γ), la Tolerancia Máxima de Faltantes ($M_{\max}$) y la Penalización Lineal por Elemento Ausente (β). Todas las pruebas fueron ejecutadas utilizando de manera uniforme el inventario de control doméstico real de 46 ingredientes. Los hallazgos se consolidan de forma sistemática en la *Tabla 5*.

El análisis de las trazas de ejecución permite validar el comportamiento real del algoritmo de búsqueda local y revela dinámicas de gran valor sobre cómo influye la calibración de los hiperparámetros en la calidad de las recomendaciones.

El Fenómeno del Confinamiento Trivial (Configuraciones C1 a C3): Bajo condiciones de rigidez extrema ($\gamma = 0,90$, $M_{\max} = 1$, $\beta = 0,50$), la función objetivo opera prácticamente como un filtro estricto de coincidencia exacta. La severa penalización lineal castiga instantáneamente cualquier ausencia y la elevada exigencia angular del coseno impide aplicar flexibilidades semánticas en la despensa.

Como consecuencia, el algoritmo se ve confinado en soluciones triviales o monocomponentes de solapamiento perfecto, aislando preparaciones extremadamente elementales como *Harina de arroz casera* o *Paletas heladas de limón*. Aunque el *Fitness* final alcanza la perfección matemática (1,0000), la utilidad práctica del recomendador disminuye para el usuario, ya que sugiere platos que apenas aprovechan el potencial combinatorio de los ingredientes disponibles en la nevera.

Punto de Equilibrio y Sustitución Lógica (Configuraciones C4, C6, C7 y C8): Las pruebas intermedias confirman que el rango óptimo para equilibrar flexibilidad y coherencia se sitúa en los umbrales $\gamma \in [0,70, 0,80]$. En la configuración **C4**, el ingrediente ausente *miel de caña* fue sustituido con éxito por la *miel* disponible en la despensa, logrando una similitud de 0,9982 que da como resultado una receta (*Salsa de kiwi*) perfectamente viable.

5.1. Optimización monobjetivo y cobertura semántica en el espacio latente

Config.	γ	$M_{\max}$	β	Receta Seleccionada Top	Fitness	Sustituciones	Faltantes
C1	0.90	1	0.50	Budín de limón sin huevo	1.0000	Ninguna	0
C2	0.90	1	0.50	Harina de arroz casera	1.0000	Ninguna	0
C3	0.90	1	0.50	Paletas heladas de limón	1.0000	Ninguna	0
C4	0.80	2	0.40	Salsa de kiwi	0.9982	Miel de caña → Miel	0
C5	0.85	3	0.30	Pavo en salsa de tomate	0.5859	Champiñones → Jamón	Pavo
C6	0.75	4	0.30	Tortilla de patata y cebolla	1.0000	Ninguna	0
C7	0.75	4	0.30	Bizcocho sano	1.0000	Ninguna	0
C8	0.70	3	0.35	Huevos al gratén	0.9735	Jamón → Jamón serrano Pimientos → Pimiento verde	0
C9	0.78	4	0.20	Masa para tacos con harina	1.0000	Ninguna	0
C10	0.60	4	0.15	Quesadillas de pollo y queso	0.9784	Salsa → Salsa de soja	0
C11	0.55	5	0.05	Crema chantilly con leche ev.	0.9795	Postre de azúcar → Azúcar	0
C12	0.55	5	0.05	Arroz al queso	0.9700	Cebollín → Orégano	0
C13	0.55	5	0.05	Huevos con epazote	0.9996	Aceite de olivo → Aceite	0

Tabla 5.2: Resultados empíricos de la búsqueda local bajo diferentes escenarios de hiperparámetros.

Del mismo modo, la configuración **C8** ($\gamma = 0,70$) demuestra el potencial de la generalización semántica para resolver recetas complejas adaptadas al inventario real: el sistema mapeó con éxito *jamón* hacia *jamón serrano* y la entidad genérica *pimientos* hacia el ingrediente específico *pimiento verde*, devolviendo la receta *Huevos al gratén* con una aptitud excelente de 0,9735.

Impacto de la Permisividad y Gestión de Ingredientes Secundarios (Configuraciones C5, C12 y C13): El hallazgo empírico más interesante surge al analizar el comportamiento del algoritmo en escenarios de alta tolerancia ($\gamma = 0,55$) y baja penalización ($\beta = 0,05$). Al reducir la exigencia geométrica, la similitud del coseno se vuelve muy laxa, lo que produce efectos contrapuestos según la jerarquía del ingrediente dentro del plato.

Por un lado, esta permisividad puede dar lugar a soluciones aceptables; un ejemplo claro se observa en la configuración **C12**, donde el sistema sustituye el *cebollín* por *orégano* para recomendar un *Arroz al queso*. Al tratarse de un ingrediente complementario que opera como

aderezo, el intercambio es culinariamente razonable. Sin embargo, el riesgo crítico de relajar tanto los parámetros se manifiesta cuando esta misma laxitud afecta a los componentes troncales de la receta. Así ocurre en la configuración C5, donde el sistema valida el cambio de *champiñones* por *jamón*, pero la baja penalización permite recomendar un *Pavo en salsa de tomate* subóptimo (0,5859) al que además le falta su proteína base (*pavo*).

Al observar las trazas experimentales, se evidencia que durante la optimización holística de la medida de *Fitness*, la propia inercia del gradiente matemático y la cobertura semántica guían al modelo de forma que resulta muy poco común encontrar soluciones finales con ingredientes faltantes significativos. Al converger de manera natural hacia zonas de compatibilidad estructural, no es necesario introducir un castigo punitivo elevado para desplazar al buscador de estas regiones.

Este contraste empírico justifica la necesidad de calibrar cuidadosamente la arquitectura de control desarrollada. Demuestra que el éxito del recomendador no consiste en maximizar ciegamente el *Fitness*, sino en ajustar los umbrales para que el sistema mantenga la flexibilidad sin comprometer la viabilidad de la receta.

5.1.3. Búsqueda Local Guiada con Mecanismo de Perturbación Condicionada

Como paso intermedio hacia modelos de optimización estocástica más complejos, se diseñó e implementó un algoritmo de Búsqueda Local avanzado. A diferencia de un enfoque de ascenso estricto o *Hill Climbing* puro, el cual sufre una alta vulnerabilidad a quedar atrapado de forma inmediata en el primer óptimo local que encuentra [2, 31], esta variante introduce un operador de vecindario acotado y un mecanismo periódico de perturbación estocástica condicionada. Esta aproximación metodológica comparte fundamentos directos con la estrategia de Búsqueda Local Iterada (*Iterated Local Search* o ILS), donde los ciclos alternos de explotación y perturbación controlada evitan la convergencia prematura [32].

Para el despliegue inicial y por defecto de esta arquitectura, **se ha adoptado un modelo de vecindario continuo basado en la similitud del coseno sobre los vectores medios (*Mean Embeddings*) de las recetas**. El propósito de esta elección de partida es explotar las regiones de alta afinidad semántica descubiertas por el modelo *Word2Vec* sin perder por completo la capacidad de exploración global a lo largo de las iteraciones. No obstante, dado que esta topografía continua puede imponer restricciones de movilidad, la evaluación de funciones de vecindario alternativas —como el enfoque discreto basado en la similitud combinatoria de Jaccard— se abordará de forma sistemática en las secciones experimentales posteriores como un análisis de robustez.

5.1.3.1. Formalización del Proceso de Explotación y Perturbación

El comportamiento dinámico de este motor de búsqueda se rige por dos fases operacionales bien diferenciadas que se ejecutan cíclicamente dentro del límite de iteraciones configurado:

1. **Explotación Local mediante Muestreo de Vecindario Continuo:** En cada iteración

i , en lugar de evaluar recetas al azar en todo el corpus, el algoritmo restringe su foco al vecindario inmediato del estado actual (idx_{actual}). Utilizando la matriz de vectores continuos original de partida, se extrae un subconjunto con las 10 recetas que presentan la mayor similitud del coseno respecto al centroide de la receta de referencia. El algoritmo selecciona uniformemente al azar un candidato de este vecindario (X_{vecino}). La transición de estado se consolida únicamente si el candidato ofrece un rendimiento estrictamente superior al mejor registro histórico de la secuencia:

$$\text{Si } \text{Score}(X_{vecino}) > \text{Score}_{mejor} \implies \begin{cases} \text{Score}_{mejor} = \text{Score}(X_{vecino}) \\ X_{actual} = X_{vecino} \end{cases}$$

2. **Perturbación Estocástica Condicionada (Escape):** Para mitigar el estancamiento prematuro en mesetas del espacio latente, se integra un operador de reinicio que se activa de forma discreta cada vez que la iteración actual es un múltiplo del hiperparámetro de control (if $i \pmod{\text{INDICE_EXPLORACION}} = 0$). Cuando esta condición se cumple, el algoritmo selecciona una coordenada completamente aleatoria en el corpus (idx_{temp}).

Para evitar que el motor destruya por completo el progreso acumulado saltando a regiones de nula compatibilidad (lo que degradaría la eficiencia del algoritmo transformándolo en una búsqueda aleatoria ciega), se aplica un filtro de aceptación geométrica de umbral estático basado en principios de perturbación débil y retención de memoria estructural de la solución:

$$\text{Si } \text{Score}(X_{temp}) > 0,5 \cdot \text{Score}_{mejor} \implies idx_{actual} = idx_{temp}$$

5.1.3.2. Evaluación Experimental y Análisis de Resultados

Para validar el impacto del operador de perturbación y calibrar su frecuencia óptima, se sometió al algoritmo a una batería de pruebas bajo tres escenarios de exploración corporativa ($\text{INDICE_EXPLORACION} = 20, 10, 30$). Se mantuvieron congelados los hiperparámetros base del entorno de simulación: $\text{MAX_FALTANTES} = 4$, $\text{PENALIZACION_FALTANTE} = 0,15$ y $\text{UMBRAL} = 0,8$. Las trazas cuantitativas de control obtenidas se consolidan en la Tabla 5.3.

El análisis empírico de las trazas revela dinámicas de comportamiento críticas asociadas a la tasa de perturbación:

Por un lado, la configuración con $\text{INDICE_EXPLORACION} = 20$ demuestra una transición fluida cuando la topografía del vecindario es densa. En la traza ID 3, partiendo de una receta inválida (*Torta keto*, $\text{Score} = 0,00$), el algoritmo rompe el estancamiento inicial en solo dos iteraciones saltando hacia variantes afines (*Bizcocho de avena* y *Banana bread*). Tras sufrir una perturbación en fases intermedias, el motor altera la trayectoria local y aterriza en una nueva cuenca de atracción que le permite encadenar mejoras locales finas hasta alcanzar la convergencia absoluta en la iteración 164 con *Pancakes esponjosos* ($\text{Score} = 1,00$).

5. EXPERIMENTACIÓN DE METAHEURÍSTICAS

ID	I. Exp.	Receta Inicial	Score I.	Score F.	Receta Final (Óptimo)	Estado Material
1	20	Tartaleta de manzana	0.40	0.97	Alitas de pollo lemon pepper	Éxito (Sust.)
2	20	Bollos suizos caseros	0.52	0.85	Buñuelos de la abuela	Faltantes: 1
3	20	Torta keto	0.00	1.00	Pancakes esponjosos	Éxito Absoluto
4	10	Paella alicantina	0.00	1.00	Rosquitas sin manteca	Éxito Absoluto
5	10	Budín de frutos secos	0.50	1.00	Pancakes esponjosos	Éxito Absoluto
6	10	Panellets de membrillo	0.00	0.97	Wrap de pollo y vegetales	Éxito (Sust.)
7	30	Helado casero	0.70	1.00	Caramelo para quesillo	Éxito Absoluto
8	30	Tartaleta de fresa	0.00	0.97	Mayonesa sin huevo ni leche	Éxito (Sust.)
9	30	Bizcochitos de crema	0.62	0.80	Fideos de arroz con verduras	Faltantes: 1

Tabla 5.3: Métricas de rendimiento e impacto del índice de exploración en la Búsqueda Local Avanzada.

Por otro lado, la intensificación del pulso a $INDICE_EXPLORACION = 10$ incrementa notablemente la robustez frente a bloqueos severos. En el caso de la *Paella alicantina* (ID 4) y los *Panellets de membrillo* (ID 6), el algoritmo se enfrenta a recetas iniciales con $Score = 0,00$ debido a incompatibilidades duras de ingredientes. Al forzar reinicios estocásticos más frecuentes, el motor efectúa saltos transversales en el corpus culinario. Esto se evidencia en la traza ID 6, donde el algoritmo transiciona de forma drástica desde dulces tradicionales (*Panellets*) hacia la gastronomía mexicana (*Enchiladas*, *Torta de chilaquiles* y *Chilaquiles con crema*) tras inyectar coordenadas aleatorias viables, logrando salvar la ejecución y estabilizarse en un *Wrap de pollo y vegetales* con un 0,97.

Finalmente, la parametrización rezagada de $INDICE_EXPLORACION = 30$ exhibe una fuerte tendencia a la explotación conservadora. Si bien es altamente eficiente para refinar recetas iniciales estables (como en la traza ID 7, donde evoluciona un *Helado casero* de 0,70 a 1,00), se vuelve vulnerable ante vecindarios dispersos. En la traza ID 9, el motor se estanca prematuramente en la receta de *Fideos de arroz con verduras* ($Score = 0,80$). Debido a que las perturbaciones tardan 30 iteraciones en activarse, el algoritmo pasa ciclos prolongados explotando un vecindario local agotado, lo que le impide saltar a tiempo a otras regiones del corpus.

5.1.3.3. Insuficiencia Estructural y Necesidad de un Modelo Dinámico

A pesar de que esta arquitectura avanzada con operadores de escape mejora sustancialmente la movilidad del sistema frente a una búsqueda lineal elemental, el análisis de las trazas

revela dos debilidades estructurales que limitan su idoneidad como optimizador global:

En primer lugar, el mecanismo de perturbación opera de manera **discontinua y ciega**. La activación del escape mediante operadores aritméticos modulares se ejecuta de forma síncrona según el número de iteraciones acumuladas, ignorando por completo el estado real del sistema. Esto provoca una ineficiencia dual: el algoritmo inyecta perturbaciones destructivas cuando se encuentra en pleno gradiente ascendente de optimización hacia una solución excelente, mientras que, por el contrario, permanece estancado durante decenas de ciclos en cuencas subóptimas esperando a que se cumpla la ventana temporal del hiperparámetro.

En segundo lugar, el criterio de filtrado estático ($0,5 \cdot \text{Score}_{\text{mejor}}$) impone una frontera rígida e inflexible que malogra el balance entre exploración y explotación. En las fases tempranas del proceso, este umbral del 50 % resulta excesivamente permisivo, consolidando saltos aleatorios de baja calidad que ralentizan la convergencia. En contraposición, durante las etapas tardías de refinamiento fino, el umbral se vuelve drásticamente restrictivo, bloqueando transiciones marginalmente descendentes que podrían actuar como pasarelas semánticas hacia óptimos globales superiores.

Estas restricciones metodológicas evidencian la necesidad de abandonar los umbrales estáticos en favor de un marco matemático probabilístico. El sistema requiere un motor donde la admisión de soluciones de inferior calidad esté regulada dinámicamente por un parámetro de control decreciente (análogo a un esquema de enfriamiento físico), permitiendo al algoritmo transitar de manera natural desde un comportamiento altamente estocástico y exploratorio al inicio, hacia una convergencia puramente determinista e intensificadora al final del ciclo de cómputo. Esta evolución matemática se formaliza en la siguiente sección mediante la arquitectura de *Simulated Annealing*.

5.1.4. Evaluación de Alternativas Heurísticas mediante Simulated Annealing

Dentro del conjunto de estrategias evaluadas para analizar el comportamiento y la optimización del *overlap* semántico en el espacio latente, se integró y testeó una variante de búsqueda local basada en la metaheurística de Simulated Annealing [14, 33]. La inclusión de este algoritmo en el banco de pruebas experimental responde al propósito de explorar si una dinámica de transición estocástica —en lugar de un enfoque de ascenso estricto— permite obtener un abanico de recomendaciones con mejor sintonía de ingredientes y evaluar la capacidad del sistema para evitar el estancamiento en óptimos locales del corpus de recetas.

Al igual que en el modelo de búsqueda local guiada, la definición del vecindario para el proceso de recocido aprovecha de primeras la topografía continua proporcionada por la similitud del coseno entre los vectores promediados de las recetas. Este enfoque unifica la línea base de representación y permite evaluar el impacto estocástico puro del algoritmo bajo las mismas condiciones del relieve continuo.

Inspirado en el proceso físico de recocido en metalurgia, donde el enfriamiento lento y controlado de un material minimiza su energía interna, este algoritmo introduce una variable paramétrica de temperatura (T) para regular de forma orgánica la permisividad del motor de

búsqueda a lo largo de las iteraciones:

- **Fase Inicial (Alta Temperatura):** El sistema dispone de una mayor flexibilidad matemática, permitiendo de manera probabilística aceptar transiciones hacia recetas con una puntuación de *overlap* inferior a la actual. El objetivo de testear esta fase es analizar si el motor logra saltar barreras de baja puntuación para descubrir combinaciones culinarias dispersas pero potencialmente óptimas.
- **Fase Final (Baja Temperatura):** A medida que el gradiente térmico desciende, el algoritmo reduce de forma drástica su tolerancia al riesgo, comportándose de manera estrictamente selectiva para refinar y explotar las sustituciones vectoriales finas (*Word2Vec*) en el vecindario de las mejores soluciones localizadas hasta el momento.

5.1.4.1. Formalización Matemática del Operador Evaluado

El diseño del algoritmo analizado dentro de este escenario experimental se rige por las siguientes especificaciones técnicas y matemáticas:

1. **Muestreo del Vecindario Vectorial Continuo (Línea Base):** Para cada receta evaluada en una iteración (idx_{actual}), el espacio de búsqueda vecina se acota explotando inicialmente la topografía de los embeddings. Se extraen las 10 recetas más cercanas en el espacio continuo mediante el cálculo de la similitud del coseno sobre la matriz global del corpus (*matriz_vectores*):

$$\text{Vecinos}(X_{actual}) = \text{Top-10} \left(\arg \max_j \frac{X_{actual} \cdot X_j^\top}{\|X_{actual}\| \|X_j\|} \right)$$

De este subconjunto de recetas geoméricamente similares, el algoritmo selecciona una al azar (X_{vecino}) para comprobar su aptitud frente al inventario del usuario. La idoneidad de esta matriz continua frente a formulaciones topológicas discretas alternativas será contrastada críticamente en la fase experimental del estudio.

2. **Criterio de Transición de Boltzmann:** En caso de que la receta candidata ofrezca una puntuación inferior, el desplazamiento no se descarta de forma lineal. El diferencial de rendimiento se define como $\Delta E = \text{Score}(X_{vecino}) - \text{Score}(X_{actual}) < 0$, y la probabilidad de aceptación (P_a) se calcula mediante la función exponencial de Boltzmann, ampliamente extendida en algoritmos de aceptación estocástica [15, 34]:

$$P_a = \exp \left(\frac{\Delta E}{T} \right) = \exp \left(\frac{\text{Score}(X_{vecino}) - \text{Score}(X_{actual})}{T} \right)$$

A través de la generación de un valor pseudoaleatorio uniforme $r \sim \mathcal{U}(0, 1)$, el sistema valida la transición si $r < P_a$. Esto asegura matemáticamente que la exploración de alternativas sea fluida al principio de la ejecución (T alta) y se congele gradualmente hacia la explotación pura cuando $T \rightarrow 0$.

3. **Parámetros de Control del Enfriamiento:** La velocidad a la que se reduce la tolerancia exploratoria se controla mediante un factor de atenuación geométrica $\alpha \in (0, 1)$, que define el esquema clásico de enfriamiento propuesto para esta metaheurística [35], actualizando la variable en cada paso k :

$$T_{k+1} = T_k \times \alpha$$

Para las pruebas de rendimiento llevadas a cabo en este bloque experimental, los hiperparámetros de control se fijaron en $T_{inicial} = 100,0$, $T_{mnima} = 0,01$ y un factor de enfriamiento $\alpha = 0,93$. Esta configuración se diseñó para observar cómo afecta un descenso progresivo en la estabilidad y evolución de las puntuaciones de coincidencia a lo largo del límite máximo de iteraciones configurado.

5.1.4.2. Análisis Experimental y Comparativa de Resultados

Con el propósito de evaluar y contrastar el rendimiento operativo de las tres filosofías de búsqueda monobjetivo desarrolladas, se ha diseñado un escenario experimental unificado.

Para garantizar la significación estadística y mitigar el sesgo derivado de la inicialización estocástica, cada optimizador fue sometido a un protocolo de 10 réplicas independientes bajo un régimen de cómputo de 1,000 iteraciones. A fin de realizar un análisis de sensibilidad y robustez profundo, se plantearon dos entornos de inventario diferenciados: el **Escenario Base** (despensa amplia de 45 ingredientes) y el **Escenario de Estrés y Restricción Extrema** (inventario contraído a solo 10 ingredientes: Pollo, Arroz, Huevo, Cebolla, Pimiento verde, Leche, Harina de trigo, Plátano, Aceite y Sal). Los indicadores estadísticos macroscópicos consolidados en ambas pruebas se recopilan en la Tabla 5.4.

	Escenario Base (45 Ingredientes)			Escenario de Estrés (10 Ingredientes)		
Algoritmo de Búsqueda	Fit. Máx.	Media (μ)	Desv. (σ)	Fit. Máx.	Media (μ)	Desv. (σ)
Búsqueda Aleatoria (BLS)	1.0000	1.0000	0.0000	1.0000	0.9597	0.0336
Búsqueda Iterada (ILS)	1.0000	0.9970	0.0067	0.9400	0.7030	0.1458
Recocido Simulado (SA)	1.0000	0.8220	0.1139	0.6500	0.3340	0.2241

Tabla 5.4: Indicadores estadísticos de rendimiento combinados a 1,000 iteraciones según la complejidad del inventario bajo la representación continua original.

Saturación y Anomalías del Rendimiento bajo Representación Continua: El análisis inicial de los datos revela un comportamiento anómalo que desafía la lógica convencional de la teoría de la optimización. Mientras que la Búsqueda Local Aleatoria (BLS) registra una convergencia perfecta en el Escenario Base ($\mu = 1,0000$) y sobresaliente en el Escenario

de Estrés ($\mu = 0,9597$), las dos metaheurísticas avanzadas basadas en vecindad (ILS y SA) experimentan una degradación drástica de sus métricas al incrementar la complejidad del entorno.

En primera instancia, se evaluó la hipótesis de que este colapso respondiera a una insuficiencia física de ingredientes en el Inventario de Estrés o a una mala calibración de parámetros en el *Simulated Annealing*. Sin embargo, dicha conjetura debió ser descartada: las pruebas complementarias reduciendo la temperatura inicial y expandiendo masivamente el presupuesto computacional a 10,000 iteraciones mantuvieron estancados los rendimientos del SA sin reflejar mejoras notables. Del mismo modo, el hecho de que el BLS Random localizara óptimos absolutos demostró que el espacio de estados contenía soluciones viables y que el problema real radicaba en la incapacidad de las metaheurísticas para transitar eficientemente hacia ellas.

Esta evidencia empírica desplazó el foco del análisis hacia un defecto estructural subyacente:

La formulación original representa cada receta mediante el vector medio (*Mean Embedding*) de sus ingredientes en el espacio de *Word2Vec*. Teóricamente, las metaheurísticas basadas en trayectoria (como el SA o el ILS) están dotadas de mecanismos estocásticos diseñados explícitamente para escapar de óptimos locales. Sin embargo, su parálisis en este escenario presenta la posibilidad de que la vecindad basada en distancias continuas arrastre un sesgo de origen.

Pruebas utilizando el Vecindario Discreto de Jaccard Para validar de si la causa raíz del problema residía en el colapso semántico de los *Mean Embeddings*, se diseñó e implementó un paradigma alternativo de vecindad estructural en tiempo de ejecución. Se eliminó por completo la proyección geométrica continua y se sustituyó por una función de vecindario basada en la Similitud Discreta de Jaccard. Bajo este nuevo marco, el catálogo se reconfigura como un grafo de interconexión puramente combinatorio, definiendo que la vecindad de una receta está constituida por las 10 preparaciones del corpus que comparten el mayor porcentaje de ingredientes reales (intersección sobre unión), con independencia de su etiqueta semántica latente.

Los volcados empíricos obtenidos al someter este nuevo espacio de búsqueda al Escenario de Estrés (10 ingredientes) desvelaron un giro metodológico de gran relevancia, cuyas trazas se exponen a continuación.

Resultados y Análisis del Impacto de Jaccard en las Metaheurísticas: La introducción del vecindario discreto alteró notablemente la dinámica de los algoritmos según el tamaño de la despensa:

1. **Impacto de la Despensa en el Simulated Annealing (SA):** En el escenario de 10 ingredientes, Jaccard solo alivió un poco el problema subiendo la media a $\mu = 0,5970$. Aunque consiguió ciertos aislados como el *Mousse de limón* (1,00), demostró

5.1. Optimización monobjetivo y cobertura semántica en el espacio latente

Algoritmo (con Jaccard)	Escenario de Estrés (10 Ingredientes)			Escenario Base (45 Ingredientes)		
	Fit. Máx.	Media (μ)	Desv. (σ)	Fit. Máx.	Media (μ)	Desv. (σ)
Búsqueda Local Guiada (ILS)	0.6500	0.2490	0.1989	1.0000	0.8830	0.1557
Simulated Annealing (SA)	1.0000	0.5970	0.2374	1.0000	0.9980	0.0063

Tabla 5.5: Indicadores estadísticos consolidados a 500 iteraciones utilizando la función de vecindario discreto de Jaccard en ambos entornos.

que con pocos ingredientes el algoritmo sigue siendo inestable. Sin embargo, al pasar al Escenario Base de 45 ingredientes, el SA con Jaccard funciona de forma impecable ($\mu = 0,9980$, $\sigma = 0,0063$), encadenando plenos absolutos como *Pancakes esponjosos* o *Tortilla de patata*. Esto confirma que con una despensa amplia, el SA se mueve con total libertad y eficacia por las conexiones reales de Jaccard.

2. **Inestabilidad Estructural por Falta de Gradiente (ILS):** Por su parte, la Búsqueda Local Guiada sufre mucho más la naturaleza discreta de Jaccard. En el escenario de 10 ingredientes colapsó por completo ($\mu = 0,2490$). Al ampliar la despensa a 45 ingredientes, el algoritmo lógicamente mejora por la abundancia de opciones ($\mu = 0,8830$), pero mantiene una alta volatilidad ($\sigma = 0,1557$). Sus resultados dan tumbos e irregularidades, cayendo en platos como *Bonito en escabeche* (0,54) o *Arroz con leche* (0,70). Al quitarle el camino continuo que le daban los vectores de *Word2Vec*, el ILS pierde su brújula de ascenso y avanza a ciegas, confirmando que este vecindario rompe su lógica de búsqueda.

Evaluación Cualitativa de la Diversidad Semántica: Los experimentos con Jaccard demuestran que el éxito del recomendador depende de cómo se conecten el espacio de búsqueda y el algoritmo. El muestreo aleatorio puro (BLS), aunque dé notas altas, tiende a la vagancia sugiriendo platos monocomponentes poco útiles. El vecindario de Jaccard ha demostrado ser una opción excelente para el *Simulated Annealing* cuando la despensa es grande, ya que ofrece una gran variedad de platos reales (desde champiñones rellenos hasta repostería). En cambio, para el ILS, este espacio plano y fragmentado arruina su capacidad de refinamiento fino.

Selección de la Arquitectura Óptima para el Motor Recomendador: El balance de todas las pruebas ratifica que la mejor configuración para el motor del recomendador monobjetivo es el Algoritmo de Búsqueda Local Iterada (ILS) operando sobre la Representación Continua de *Word2Vec*.

Las razones que justifican esta decisión se resumen en tres pilares:

1. **Sinergia Algoritmo-Espacio:** El ILS es el único que sabe aprovechar la suavidad de

los vectores continuos para subir de forma eficiente hacia recetas de alta puntuación en pocos milisegundos.

2. **Resiliencia de la Perturbación:** Mientras que el *Simulated Annealing* necesita cambiar todo su vecindario por Jaccard para no quedarse atascado en el espacio continuo, el ILS soluciona ese problema de forma nativa gracias a sus saltos de perturbación controlados.
3. **Equilibrio y Consistencia:** La combinación de ILS con el modelo continuo ofrece los resultados más estables y maduros del estudio ($\mu = 0,7030$ con pocos ingredientes y $\mu = 0,9970$ en el escenario base), garantizando recomendaciones variadas, complejas y perfectamente ajustadas al inventario del usuario.

5.2. Optimización Multicriterio y Modelado Multiobjetivo en el Espacio Latente

En los sistemas de recomendación gastronómica reales, la idoneidad de un plato no responde únicamente a la disponibilidad material de los componentes en la despensa; variables como el tiempo de preparación, la complejidad técnica o el perfil nutricional interactúan de forma directa con las restricciones y metas de salud del usuario. Por consiguiente, tras concluir la fase monobjetivo centrada en el *overlap*, esta sección expande el marco metodológico hacia un escenario donde los motores estocásticos se enfrentan a espacios de búsqueda condicionados por metas múltiples e interdependientes.

Para abordar esta complejidad de manera analítica y progresiva, la investigación se divide en dos estrategias complementarias:

1. **Enfoque Multicriterio mediante Agregación Lineal:** Unifica diversas variables continuas y discretas en una única función de aptitud indexada, asignando a cada componente un peso paramétrico normalizado (ω_i) que simula las prioridades dinámicas del usuario.
2. **Optimización Multiobjetivo Pura y Fronteras de Aptitud:** Prescinde de la unificación lineal para tratar las metas de forma independiente y contrapuesta, explorando la viabilidad de aproximar un conjunto de soluciones óptimas en el sentido de Pareto.

5.2.1. Enfoque Multicriterio mediante Agregación Lineal Estática

Esta aproximación metodológica permite fusionar variables cuantitativas y cualitativas de naturaleza heterogénea (escalas de tiempo, niveles de dificultad, gramos de nutrientes y afinidades vectoriales) en un único valor escalar indexado en el intervalo $[0, 1]$, facilitando que cualquier algoritmo de búsqueda evalúe la viabilidad global de una receta candidata.

5.2.1.1. Formulación Matemática de la Función de Aptitud

El cómputo de la aptitud global de una receta (X) se articula a través de cuatro componentes independientes y normalizados:

1. **Filtro de Viabilidad Material y Cobertura Semántica** (M_{ing}): Si el número de ingredientes requeridos ausentes (y sin sustitutos viables en el espacio *Word2Vec*) supera un umbral crítico ($C_{faltantes} > \text{MAX_FALTANTES}$), la receta se descarta automáticamente otorgando un *score* de 0,0. En caso de ser viable, se calcula el acoplamiento semántico promediado y se le aplica una penalización lineal discreta:

$$M_{ing} = \max \left(0,0, \frac{\sum \text{Puntuación}}{\|I_{receta}\|} - (C_{faltantes} \times \text{PENALIZACION_FALTANTE}) \right)$$

2. **Adecuación de la Dimensión Temporal** (M_{dur}): Modela la conformidad entre el tiempo límite disponible por el usuario (t_u) frente a la duración total o de fermentación del plato (t_r):

$$M_{dur} = \begin{cases} 1,0 & \text{si } t_r \leq t_u \\ \max \left(0,0, 1,0 - \frac{t_r - t_u}{t_u} \right) & \text{si } t_r > t_u \end{cases}$$

3. **Adecuación de la Complejidad Técnica** (M_{dif}): Mide la discrepancia entre el nivel de dificultad exigido por el plato (d_r) y la pericia declarada por el usuario (d_u), mapeados en una escala numérica discreta:

$$M_{dif} = \begin{cases} 1,0 & \text{si } d_r \leq d_u \\ \max \left(0,0, 1,0 - \Delta d_{penalizacion} \right) & \text{si } d_r > d_u \end{cases}$$

4. **Optimización de la Densidad Nutricional** (M_{nut}): Evalúa el aporte de proteínas y fibra aplicando funciones de saturación sobre umbrales dietéticos de control (50g para proteínas y 20g para fibra):

$$P_{prot} = \min \left(\frac{\text{Proteínas}}{50,0}, 1,0 \right), \quad P_{fib} = \min \left(\frac{\text{Fibra}}{20,0}, 1,0 \right) \implies M_{nut} = \frac{P_{prot} + P_{fib}}{2,0}$$

La consolidación matemática final se realiza mediante el producto escalar con el vector de pesos normalizados ($\sum \omega_i = 1,0$), permitiendo modular dinámicamente el perfil del recomendador:

$$\text{Fitness}(X) = (\omega_{ing} \cdot M_{ing}) + (\omega_{nut} \cdot M_{nut}) + (\omega_{dur} \cdot M_{dur}) + (\omega_{dif} \cdot M_{dif})$$

5.2.1.2. Tratamiento de Metadatos Ausentes y Estrategia Experimental

Un desafío técnico detectado durante la fase de análisis del corpus es la presencia de ruido e incompletitud en los datos de origen; un volumen significativo de recetas carece de propiedades de procesamiento críticas en sus campos estructurados (v.g., registros donde la fibra no está computada, campos vacíos en los tiempos de elaboración o dificultades no indexadas). Al activar funciones de aptitud multicriterio, la ausencia de estos metadatos introduce el riesgo de sesgar el comportamiento de los algoritmos o provocar fallos de ejecución por valores nulos.

Para mitigar este impacto y evaluar la robustez de las metaheurísticas ante la calidad del dato, el banco de pruebas experimental se ha dividido de forma estricta en dos categorías independientes de ensayos:

1. **Categoría A (Filtrado por Eliminación Completa):** En esta primera serie de pruebas, se aplica una política restrictiva de limpieza de datos en el preprocesamiento. Se descartan por completo del espacio de búsqueda todas aquellas recetas que presenten omisiones en cualquiera de sus variables secundarias (nutrición, tiempo o dificultad). De un total inicial de 12,553 recetas que componen el corpus bruto, este filtro purga un volumen de 2,179 registros que carecen de datos reales, consolidando un corpus limpio final de 10,374 recetas restantes. Esta aproximación garantiza una evaluación con máxima certeza matemática sobre preparaciones con información 100 % real, aunque reduce un 17.36 % el tamaño del universo de soluciones disponible, contrayendo la densidad de caminos sintácticos e itinerarios combinatorios que los algoritmos pueden explotar en el espacio latente.
2. **Categoría B (Imputación mediante Medidas de Tendencia Central):** En la segunda serie, se mantiene la integridad total del corpus original. Para no reducir el espectro de recomendaciones, los campos vacíos son sustituidos dinámicamente mediante la media aritmética de los valores válidos de dicha variable a nivel global (o la moda cualitativa en el caso de la dificultad técnica). Este enfoque de imputación estadística permite analizar si los algoritmos mantienen su eficiencia exploratoria en un entorno densificado y si la introducción de valores promedio altera la convergencia hacia los óptimos locales reales.

5.2.2. Análisis Comparativo del Impacto del Preprocesamiento en las Metaheurísticas

Para evaluar de manera empírica la influencia de las estrategias de tratamiento de metadatos ausentes sobre los motores de optimización, se ha diseñado un escenario de control unificado ejecutado bajo un entorno estricto de réplicas estocásticas independientes. Los parámetros operativos y el inventario del perfil de usuario de prueba se han congelado con las siguientes especificaciones técnicas:

- **Perfil de Inventario y Restricciones del Usuario:** Despensa acotada a una lista indexada de 45 ingredientes base, con una restricción de dificultad culinaria fijada en nivel medio (2) y un umbral máximo de duración de la preparación temporalizado en 50 minutos.
- **Hiperparámetros del Entorno de Simulación:** Cota máxima de desabastecimiento permitida de $MAX_FALTANTES = 4$, coeficiente de penalización por falta de un ingrediente $PENALIZACION_FALTANTE = 0,1$, umbral semántico de corte para sustituciones vectoriales $UMBRAL = 0,8$ y una frecuencia operativa del operador de perturbación parametrizada en $INDICE_EXPLORACION = 20$.

Los resultados estadísticos se consolidan en la Tabla 5.6.

Algoritmo	Estrategia del Corpus	Fitness Máx.	Fitness Medio (μ)	Desv. Estándar (σ)
BLI	Depurado (Cat. A)	0.9400	0.9190	0.0137
	Imputado (Cat. B)	0.9600	0.9340	0.0246

Tabla 5.6: Indicadores estadísticos de rendimiento del algoritmo ILS Continuo a 500 iteraciones.

La lectura de las métricas desvela que el ILS Continuo mantiene una consistencia sobresaliente en ambos entornos, reflejando desviaciones estándar muy bajas ($\sigma \approx 0,01$ y $\sigma \approx 0,02$). Esto demuestra que, gracias a su operador de perturbación estocástica condicionada, el algoritmo mapea y refina las soluciones de manera sistemática a lo largo de las regiones de alta afinidad semántica, sin sufrir los bloqueos ni la volatilidad que penalizaban a otras metaheurísticas.

Los resultados demuestran que el entorno imputado ofrece métricas ligeramente superiores. Este comportamiento es lógico y esperable, ya que al mantener el volumen original del catálogo mediante el rellenado de datos, el algoritmo dispone de un abanico más amplio de recetas que pueden cumplir con la restricción de ingredientes, facilitando la localización de platos con alta puntuación. Sin embargo, al comprobar que la ganancia en la aptitud promedio es tan pequeña, se concluye que este incremento marginal no justifica la introducción de más de 2,000 instancias con datos artificiales o erróneos. Por tanto, se ratifica la depuración por eliminación como la única vía metodológica aceptable, priorizando la veracidad y calidad real del sistema por encima de un leve espejismo numérico en las tablas de rendimiento.

5.2.3. Planteamiento del Enfoque Multiobjetivo Real y la Frontera de Pareto

A pesar de que el modelo de agregación lineal estática empleado en las secciones previas ofrece una solución computacionalmente eficiente, cuenta con una limitación metodológica intrínseca: la necesidad de definir a priori un vector de pesos de ponderación ($\vec{\omega}$). Para superar esta rigidez, este apartado introduce un enfoque de optimización multiobjetivo real fundamentado en el concepto de la *Frontera de Pareto*.

La optimización multidimensional bajo este paradigma no busca una única receta "perfecta", sino un conjunto de soluciones analíticamente equivalentes donde es matemáticamente

imposible mejorar uno de los criterios sin degradar perjudicialmente otro [36]. En este contexto, una receta A domina a una receta B en el sentido de Pareto si y solo si A es estrictamente superior a B en al menos una de las dimensiones y no es inferior en ninguna de las demás. El objetivo final del sistema transiciona, por tanto, de maximizar un único *Fitness Score* escalar a proyectar la frontera geométrica que delimita las mejores tasas de compromiso (*trade-offs*) posibles para el usuario.

Para construir este espacio de optimización multiobjetivo real, los pesos que anteriormente penalizaban o premiaban de forma agregada la función objetivo se segregan y se reformulan como funciones objetivo independientes y concurrentes. De este modo, cada receta del corpus se evalúa de manera simultánea en un espacio tetradimensional definido por las siguientes funciones:

1. **Dimensión de Cobertura de Inventario (f_{ing}):** Maximiza la viabilidad material del plato en función de la despensa del usuario. Evalúa la proporción de ingredientes requeridos que están físicamente disponibles en el hogar, penalizando de forma estricta la necesidad de insumos externos faltantes y gobernando el uso de los operadores de sustitución semántica.
2. **Dimensión de Densidad Nutricional (f_{nut}):** Maximiza el perfil biológico de la preparación culinaria. En lugar de diluirse en una suma ponderada, esta función opera de forma aislada para rastrear y maximizar de forma neta la concentración de macronutrientes críticos (v.g., proteínas y fibra) solicitados en las restricciones del perfil de usuario.
3. **Dimensión de Optimización Temporal (f_{dur}):** Minimiza el tiempo total de ejecución y preparación física de la receta. Actúa como una fuerza de presión contrapuesta a las dimensiones de complejidad, buscando descartar las preparaciones de cocción lenta y priorizar aquellas que converjan eficientemente hacia la cota temporal ideal establecida por el usuario.
4. **Dimensión de Simplicidad Técnica (f_{dif}):** Minimiza el nivel de dificultad e infraestructura técnica requerida para la elaboración del plato. Esta función analiza las variables cualitativas de complejidad de los pasos con el objetivo de retener soluciones que resulten accesibles y viables operativamente para el perfil del usuario.

Al tratar estas cuatro características como componentes independientes de un vector de aptitud multifuncional $\vec{F}(x) = [f_{ing}(x), f_{nut}(x), f_{dur}(x), f_{dif}(x)]$, el sistema es capaz de generar una frontera de decisión rica y diversa. Esto permitirá al recomendador ofrecer un catálogo de alternativas óptimas (v.g., un plato extremadamente rápido pero con sutiles faltantes, frente a otro nutricionalmente perfecto pero que requiere mayor tiempo de elaboración), delegando la decisión final en el criterio del usuario sin sesgos paramétricos previos.

5.2.4. Resultados Experimentales de la Frontera de Pareto bajo Imputación por Tendencia Central

Con el fin de evaluar de forma empírica el comportamiento del motor de optimización evolutiva multiobjetivo ante registros incompletos, se ejecutó el algoritmo sobre el subconjunto de datos sometido previamente al pipeline de imputación por tendencia central (sustitución de valores nulos por la media aritmética global del corpus). Los perfiles de rendimiento resultantes para las recetas que consiguieron consolidarse en la frontera no dominada de Pareto se encuentran tabulados de forma detallada en la Tabla 5.7.

Índice	Nombre de la Receta	(f_{ing})	(f_{dur})	(f_{dif})	(f_{nut})
Receta 1	Receta de gachasmigas yeclanas	1.0000	0.8750	1.0000	1.0000
Receta 2	Receta de Harina de arroz casera	1.0000	1.0000	1.0000	0.7000
Receta 3	Receta de Sándwich de aguacate y atún	0.7039	1.0000	1.0000	0.9500
Receta 4	Receta de Pizza en sartén con harina	0.2772	1.0000	1.0000	1.0000

Tabla 5.7: Resultados de la Frontera de Pareto para las soluciones no dominadas empleando sustitución por la media.

El análisis de las métricas normalizadas consolidadas en la Tabla 5.7 evidencia la aparición de las tasas de compromiso geométricas (*trade-offs*) características del espacio no dominado, validando la sensibilidad del algoritmo multiobjetivo para discriminar perfiles funcionales contrapuestos:

- **Análisis de Coexistencia No Dominada:** Al contrastar la *Receta 1* y la *Receta 2*, se observa cómo ambas alcanzan la máxima viabilidad material en despensa ($f_{ing} = 1,0000$) y simplicidad de ejecución ($f_{dif} = 1,0000$). Sin embargo, la *Receta 1* sacrifica sutilmente la eficiencia temporal frente a la *Receta 2* (0,8750 frente a 1,0000) a cambio de maximizar por completo el perfil nutricional latente (1,0000 frente a 0,7000). Al no existir un vector de pesos fijo, el modelo retiene de forma justa ambas variantes al ser incapaz de priorizar el tiempo sobre el aporte biológico sin una instrucción paramétrica previa.
- **Efectos Estructurales de la Imputación por la Media:** Resulta de un alto interés crítico evaluar el comportamiento de la *Receta 3* y la *Receta 4*. Al haber rellenado de forma artificial las variables continuas faltantes del corpus utilizando el promedio estático del *dataset*, el optimizador matemático tiende a converger de manera artificial hacia valores estables idénticos de optimización temporal y simplicidad ($f_{dur} = 1,0000$ y $f_{dif} = 1,0000$).

Esta regularización forzada provoca que la frontera de decisión dependa casi en su totalidad del balanceo entre la cobertura real de la nevera (f_{ing}) y el vector nutricional recalculado (f_{nut}). La *Receta 4* se sitúa en el extremo de la frontera al ofrecer un perfil de nutrición óptimo (1,0000), asumiendo como penalización matemática colateral un riesgo crítico de desabastecimiento en el hogar, reflejado en un coeficiente de cobertura de ingredientes significativamente bajo ($f_{ing} = 0,2772$).

En conclusión, los resultados demuestran que el algoritmo multiobjetivo responde de forma matemáticamente consistente a los principios de Pareto, proveyendo un espectro diverso de soluciones viables. No obstante, la uniformidad detectada en las dimensiones temporales y técnicas abre una interrogante analítica sobre si el uso de la media aritmética introduce un sesgo de centralidad atenuante, justificando la exploración experimental de técnicas de eliminación o imputaciones avanzadas en los capítulos subsiguientes del proyecto.

5.2.5. Resultados Experimentales de la Frontera de Pareto mediante Filtrado de Registros Incompletos

Como contrapartida metodológica a la imputación por tendencia central, se procedió a evaluar el comportamiento del espacio multiobjetivo aplicando una estrategia de depuración estricta, consistente en la eliminación de todos aquellos registros del corpus que presentaran variables nulas o incompletas en sus dimensiones nativas. Tras ejecutar el optimizador sobre este subconjunto de datos normalizado, se obtuvo una nueva frontera de Pareto compuesta por seis soluciones no dominadas, cuyos perfiles vectoriales de rendimiento se detallan en la Tabla 5.8.

Índice	Nombre de la Receta	(f_{ing})	(f_{dur})	(f_{dif})	(f_{nut})
Receta 1	Receta de Harina de arroz casera	1.0000	1.0000	1.0000	0.7000
Receta 2	Receta de Pizza de varios sabores	0.7366	0.0000	1.0000	0.8750
Receta 3	Receta de Garbanzos con pulpo cocid	0.7342	0.8750	1.0000	0.8050
Receta 4	Receta de Sándwich de aguacate y at	0.7039	1.0000	1.0000	0.9500
Receta 5	Receta de Garbanzos con chocos con	0.2933	0.8750	1.0000	1.0000
Receta 6	Receta de Pizza en sartén con harin	0.2772	1.0000	1.0000	1.0000

Tabla 5.8: Resultados de la Frontera de Pareto para las soluciones no dominadas tras la eliminación de registros incompletos.

El análisis analítico de los vectores consolidados tras el filtrado del corpus revela cambios estructurales significativos en la topología de la frontera no dominada, permitiendo extraer las siguientes deducciones científicas:

- **Expansión de la Frontera y Enriquecimiento de Trade-offs:** La eliminación del ruido y de los sesgos de la imputación artificial ha permitido que la frontera de Pareto pase de cuatro a seis soluciones no dominadas. Este incremento demuestra que el algoritmo ahora dispone de datos reales y heterogéneos para identificar nichos de compromiso más granulares. Un ejemplo claro se observa al contrastar la *Receta 2*, *Receta 3* y *Receta 4*: las tres orbitan en una franja de cobertura de inventario similar ($f_{ing} \approx [0,70, 0,73]$) y comparten una idéntica simplicidad técnica ($f_{dif} = 1,0000$), pero despliegan un balanceado contrapeso en sus dimensiones de tiempo y nutrición. La *Receta 2* penaliza por completo la eficiencia temporal (0,0000) a cambio de un aporte biológico intermedio (0,8750); la *Receta 3* recupera rendimiento temporal (0,8750) cediendo sutilmente en nutrición (0,8050), mientras que la *Receta 4* se alza como una solución hiper-eficiente en tiempo (1,0000) con un perfil nutricional excelente (0,9500).

- **Desarticulación del Sesgo de Centralidad:** Al comparar estos resultados con los de la imputación por la media (Tabla 5.7), se evidencia la desaparición del efecto de regularización artificial que forzaba a la dimensión temporal (f_{dur}) a estancarse en el valor ideal de 1,0000. La aparición de valores reales dispersos como 0,0000 (*Receta 2*) u 0,8750 (*Receta 3 y 5*) demuestra que el filtrado restituye la variabilidad física del corpus. El optimizador ya no toma decisiones basadas en promedios estadísticos inventados, lo que dota a la frontera de una fidelidad matemática real respecto a las restricciones logísticas genuinas de las recetas.
- **Preservación de los Extremos de Selección Estricta:** Es notable verificar que las soluciones que representaban los límites geométricos de la frontera en el experimento previo se mantienen inmunes al cambio de estrategia de datos. La *Receta 1* (*Harina de arroz casera*) y la última solución de la tabla (*Pizza en sartén...*, listada aquí como *Receta 6*) retienen exactamente sus mismos perfiles vectoriales individuales. Esto confirma que el optimizador multiobjetivo exhibe una alta estabilidad y robustez en los extremos de la frontera, independientemente del método de tratamiento de nulos aplicado en las regiones densas o intermedias del espacio de búsqueda.

En conclusión, la estrategia de filtrado de registros incompletos mitiga con éxito el sesgo de centralidad atenuante identificado en el análisis previo, restituyendo la naturaleza multidimensional del problema culinario. Aunque esta técnica reduce el tamaño neto del corpus utilizable, la ganancia en la riqueza de los (*trade-offs*) y la veracidad de las soluciones resultantes justifican su adopción como un enfoque preferente para garantizar la robustez del motor de recomendación gastronómica.

5.3. Conclusiones Generales

Los experimentos desarrollados en este capítulo han permitido evaluar, de forma progresiva, cómo cambia el comportamiento del recomendador al pasar de un enfoque de coincidencia exacta a modelos basados en similitud semántica, y de una formulación monobjetivo a escenarios multicriterio y multiobjetivo. A partir de los resultados obtenidos, pueden extraerse las siguientes conclusiones principales:

1. **La representación semántica mejora claramente al baseline exacto, pero no resuelve por sí sola el problema de la recomendación.** La comparación entre el algoritmo determinista de conjuntos y los enfoques apoyados en embeddings confirma que la coincidencia exacta resulta demasiado rígida para el dominio culinario, ya que no tolera sinonimias, reformulaciones ni sustituciones razonables entre ingredientes próximos. En este sentido, el uso del espacio vectorial de *Word2Vec* permite flexibilizar la noción de solapamiento y recuperar recetas que el baseline descartaría pese a ser potencialmente viables. Sin embargo, los experimentos también muestran que la proximidad geométrica entre ingredientes no siempre equivale a una sustitución culinariamente adecuada. Por tanto, la similitud semántica constituye una mejora sustancial frente al

emparejamiento exacto, pero necesita mecanismos de control adicionales para evitar recomendaciones incoherentes.

2. **El rendimiento de las metaheurísticas depende tanto del algoritmo como de la estructura del espacio de búsqueda.** Los resultados del bloque monobjetivo muestran que no existe una heurística universalmente superior con independencia de la representación empleada. El comportamiento de cada algoritmo está condicionado por la topología del vecindario sobre el que opera. En particular, la búsqueda local guiada obtiene un comportamiento sólido cuando trabaja sobre el espacio continuo de *Word2Vec*, mientras que el *Simulated Annealing* presenta dificultades en esa misma representación y mejora notablemente al redefinir el vecindario mediante una lógica discreta basada en Jaccard, especialmente cuando el inventario disponible es amplio. Este hallazgo sugiere que una parte importante del rendimiento no reside únicamente en la heurística elegida, sino en la compatibilidad entre el mecanismo de exploración y la forma en que se conectan las recetas dentro del espacio de soluciones.
3. **La ampliación a múltiples criterios permite modelar de forma más realista la recomendación culinaria.** La incorporación de variables adicionales como el tiempo de preparación, la dificultad técnica y el perfil nutricional demuestra que la calidad de una recomendación no puede reducirse al solapamiento de ingredientes. La formulación multicriterio mediante agregación lineal permite integrar estas dimensiones de manera operativa y producir un criterio único de evaluación, pero mantiene la limitación de exigir una ponderación previa de objetivos. En cambio, la formulación multiobjetivo basada en dominancia de Pareto ofrece una representación más fiel del problema, al permitir recuperar soluciones no dominadas que reflejan distintos compromisos entre cobertura de despensa, nutrición y coste temporal.
4. **El tratamiento de los datos incompletos afecta de forma directa a la interpretación de los resultados.** La comparación entre imputación por tendencia central y filtrado de registros incompletos revela un intercambio claro entre cobertura del corpus y fidelidad del dato. La imputación permite conservar un mayor número de recetas y, en algunos experimentos, mejora ligeramente ciertas métricas agregadas. No obstante, también introduce regularidades artificiales que reducen la variabilidad real del espacio de soluciones, como se observa especialmente en la frontera de Pareto, donde algunas dimensiones quedan excesivamente homogeneizadas. Por el contrario, el filtrado reduce el tamaño del corpus, pero preserva mejor la heterogeneidad original de los datos y produce resultados más interpretables desde el punto de vista metodológico. Por ello, dentro de este trabajo, se considera preferible priorizar la consistencia del dato frente a mejoras marginales obtenidas mediante imputación.

En conjunto, los casos de uso analizados muestran que la recomendación culinaria flexible se beneficia claramente de la incorporación de representaciones semánticas y estrategias de optimización más allá de la coincidencia exacta. No obstante, también ponen de manifiesto que el rendimiento del sistema depende de la interacción entre varias capas: la calidad del

preprocesamiento, la representación elegida, la definición del vecindario y la heurística de búsqueda utilizada. Más que señalar una solución universal cerrada, los experimentos de este capítulo permiten identificar qué combinaciones resultan más robustas dentro del marco planteado y qué limitaciones deben seguir abordándose en fases posteriores del trabajo.

Exploración de transformers

La incorporación de modelos basados en la arquitectura de *Transformers* responde a la necesidad de superar las limitaciones analíticas de los espacios vectoriales estáticos como Word2Vec o FastText. Si bien estos últimos permiten mapear relaciones de similitud léxica globales, carecen de la capacidad de ajustar dinámicamente la representación semántica de un ingrediente en función del contexto inmediato que lo rodea. Para subsanar esta restricción y dotar al asistente de cocina de un validador contextual inteligente, se ha explorado el uso del Procesamiento del Lenguaje Natural (NLP) profundo mediante el modelo BERT (*Bidirectional Encoder Representations from Transformers*).

6.1. Selección y Justificación del Modelo Base: BETO

El desarrollo de este bloque se fundamenta en el empleo de **BETO** (`bert-base-spanish-wwm-cased`), una adaptación optimizada de la arquitectura BERT entrenada específicamente con un corpus masivo en español por la Universidad de Chile [37]. La elección de esta variante frente al BERT multidominio u otros modelos anglocéntricos se justifica por dos factores técnicos críticos:

1. **Especialización Idiomática:** Al haber sido preentrenado nativamente en español, el vocabulario del modelo preserva las raíces morfológicas y las estructuras sintácticas propias de la gastronomía hispanohablante, evitando sesgos de traducción o tokenizaciones anómalas por subpalabras (*WordPiece*) que romperían términos culinarios comunes.
2. **Estrategia Whole Word Masking (WWM):** A diferencia del enmascaramiento clásico por fragmentos silábicos, la estrategia *WWM* fuerza al modelo a enmascarar palabras completas durante su preentrenamiento. Esto resulta vital para nuestro dominio de conocimiento, ya que impide que el transformador *adivine* un ingrediente deduciendo únicamente un fragmento morfológico, forzándolo en su lugar a analizar la coocurrencia semántica global y la complementariedad de la receta.

6.2. Curación del Corpus y Selección de Atributos Gastronómicos

Tras una serie de evaluaciones empíricas preliminares, se determinó realizar una filtración estricta de la estructura física de las recetas, prescindiendo por completo de las instrucciones narrativas de elaboración y aislando únicamente el Título de la Receta y la Lista de Ingredientes. Esta decisión de diseño se fundamenta rigurosamente en dos pilares de la arquitectura de redes neuronales de atención:

- **Mitigación del Ruido Lingüístico (*Signal-to-Noise Ratio*):** Los textos de elaboración culinaria están compuestos mayoritariamente por ruido semántico distributivo (v.g., verbos de acción en imperativo como "*vierte*", instrucciones de infraestructura como "*molde circular*" o tiempos de cocción). Al alimentar al modelo con estos párrafos narrativos, las matrices de auto-atención (*Self-Attention*) dispersan sus pesos matemáticos aprendiendo sintaxis conversacional en lugar de afinidades materiales [38]. El aislamiento de los ingredientes purifica el espacio semántico, concentrando la energía del gradiente en la lógica estricta de la despensa.
- **Restricción Geométrica del Límite de Tokens:** La arquitectura nativa de BERT cuenta con una limitación computacional infranqueable de 512 tokens por secuencia de entrada debido al coste de memoria cuadrático del mecanismo de atención [39]. La inclusión de textos de preparación extensos provocaría un truncamiento forzado de las secuencias. Dado que los ingredientes críticos a menudo se reformulan o consolidan en los pasos tardíos de la elaboración, este truncamiento introduciría una pérdida de información inadmisibles. El formato simplificado garantiza que el 100 % de las muestras se sitúen holgadamente por debajo del límite, acelerando la velocidad de convergencia.

Para homogeneizar el flujo de entrada, cada una de las 12,554 recetas del corpus se reestructura en una única cadena textual compacta siguiendo el patrón formalizado:

$$\text{Secuencia}_{\text{input}} = [\text{Nombre del Plato}] \parallel \text{ingredientes: } [\text{Ingrediente}_1, \dots, \text{Ingrediente}_n.]$$

Una vez estructurada la cadena, esta es procesada por el Tokenizador de BERT, que se encarga de realizar la limpieza, convertir el texto en identificadores numéricos e inyectar los tokens especiales de la arquitectura: [CLS] al inicio de la secuencia (como vector de agregación semántica global) y [SEP] como delimitador de contextos.

6.3. Finetuning del Clasificador de Afinidad Culinaria

Con el fin de reconvertir el modelo de lenguaje en un evaluador binario de compatibilidad gastronómica, se acopló una cabeza de clasificación lineal (*Classification Head*) sobre el estado oculto final del token especial [CLS]. El entrenamiento se planteó como un problema de

clasificación binaria supervisada, donde el modelo debe predecir si una combinación de ingredientes es legítima ($y = 1$) o artificialmente alterada ($y = 0$). El proceso de optimización empleó el algoritmo AdamW con una tasa de aprendizaje adaptativa.

6.3.1. Análisis de Convergencia y Curvas de Aprendizaje

Para auditar la evolución del aprendizaje sin sesgos por fluctuaciones locales del gradiente, el proceso de entrenamiento se monitorizó dividiendo el conjunto de datos secuencialmente en diez bloques independientes (*splits*). La evolución de la función de pérdida (*Training Loss*) a lo largo de los pasos de optimización (*steps*) se detalla visualmente en la Figura 6.1.



Figura 6.1: Evolución del *Training Loss* segmentada por *splits* de entrenamiento a lo largo de los pasos de optimización para el clasificador gastronómico.

El análisis cuantitativo del *trainer_state* revela un comportamiento altamente estable. En el primer bloque (*Train Loss Split 1*), se observa un desplome abrupto de la pérdida, transitando de un error inicial superior a 0,75 hasta estabilizarse en el entorno de 0,22. Esta caída exponencial corrobora la idoneidad de la inicialización de BETO, cuyos pesos preentrenados asimilan con rapidez las restricciones sintácticas del nuevo dominio.

A medida que se suceden los bloques intermedios (del *Split 2* al *Split 5*), el gradiente modula su descenso de manera armónica, mitigando las oscilaciones estocásticas propias del minihatch. A partir del *Split 6* y hasta la culminación del proceso en el *Split 10*, el sistema alcanza una fase de asíntota y convergencia suave, donde la pérdida se confina por debajo de 0,10. La ausencia de repuntes o divergencias tardías en la pérdida de los bloques finales descarta la existencia de fenómenos de sobreajuste (*overfitting*), garantizando que las matrices de auto-atención han generalizado con éxito las reglas de coocurrencia de la cocina.

6.4. Evaluación Experimental del Espacio de Similitud Contextual

A pesar del éxito del clasificador binario para discriminar la coherencia global de una receta (v.g., penalizando combinaciones aberrantes como chocolate en platos de pescado con probabilidades inferiores al 6,00 %), la tarea de sustitución funcional de ingredientes requería una granularidad analítica superior. El clasificador determina si un plato es válido, pero no es capaz de ordenar la idoneidad fina entre múltiples candidatos viables.

Para resolver esta limitación, se diseñó un experimento basado en la **Similitud del Coseno** directamente sobre el espacio latente del token [CLS], utilizando el modelo base para extraer los embeddings contextuales refinados. El procedimiento consistió en aislar una receta real, sustraer un ingrediente objetivo para generar un escenario de necesidad, y clonar dicha secuencia vectorizándola de forma iterativa tras sustituir el espacio vacío por cada uno de los elementos de un inventario cerrado de prueba compuesto por 46 ingredientes. La similitud matemática se calculó contrastando el vector de la receta original ideal frente al vector de cada variante modificada:

$$\text{Similitud}(V_{\text{original}}, V_{\text{modificado}}) = \frac{V_{\text{original}} \cdot V_{\text{modificado}}}{\|V_{\text{original}}\| \|V_{\text{modificado}}\|}$$

Los resultados empíricos recopilados bajo distintos escenarios culinarios se consolidan en la Tabla 6.1.

Receta Objetivo	Rank	Sustituto Candidato	Similitud
POLLO COCIDO (Oculto: <i>laurel</i>)	#1	garbanzos	0.99889
	#2	aceituna	0.99855
	#3	pepino	0.99847
	#7	oregano	0.99786
MERMELADA DE KAKI (Oculto: <i>kakis</i>)	#1	kiwi	0.99665
	#2	manzana	0.97451
	#3	naranja	0.97357
	#4	huevos	0.97288
PASTA CON VERDURAS (Oculto: <i>nuez</i>)	#1	lechuga	0.99977
	#2	cebolla	0.99977
	#4	maiz	0.99973
MOUSSE DE LIMÓN (Oculto: <i>leche</i>)	#1	miel	0.99922
	#2	naranja	0.99888
	#15	chocolate	0.99788

Tabla 6.1: Métricas de asignación de similitud contextual en el inventario cerrado de la despensa de prueba.

6.4.1. Discusión de Resultados y Comportamiento del Modelo

El análisis de las métricas registradas en la Tabla 6.1 permite extraer conclusiones directas sobre cómo procesa BETO el contexto culinario del inventario cerrado:

1. **Sensibilidad a la Afinidad Categórica Directa:** El modelo exhibe un comportamiento excelente al tratar con recetas donde el ingrediente retirado define la identidad del plato. En la *Mermelada de Kaki*, al ocultar la fruta base, el sistema discrimina con éxito y sitúa en el podio opciones lógicas de la misma familia como el *kiwi* (0,99665), la *manzana* (0,97451) y la *naranja* (0,97357). Lo mismo ocurre en la *Mousse de Limón*, donde al retirar la leche, el sistema premia una alternativa dulce y viscosa como la *miel* (0,99922).
2. **Vulnerabilidad ante la Redundancia de Inventario:** Se constata que el cálculo de similitud contextual carece de una lógica interna de inventario. En la receta de *Pasta con Verduras*, la *cebolla* y el *maíz* se posicionan en puestos altos. Si bien culinariamente combinan con el plato, el sistema ignora que estos elementos ya formaban parte de los ingredientes originales de la receta, proponiendo una sustitución redundante que no aporta valor resolutorio al usuario. Sin embargo, este inconveniente presenta una solución sumamente sencilla de implementar en la práctica mediante el software de control.
3. **Comprensión del Entorno frente a la Ignorancia Funcional del Ingrediente:** Los resultados revelan una característica intrínseca de los modelos de lenguaje: BETO demuestra una comprensión sobresaliente del **contexto macroscópico** de la receta, asimilando con éxito qué tipo general de ingredientes 'encajan'. En la prueba del *Pollo Cocido*, el modelo sitúa en los primeros puestos a los *garbanzos*, las *aceitunas* o el *pepino* porque reconoce de manera abstracta que pertenecen al entorno de platos salados, carnes o guisados.

Sin embargo, el transformer carece de conocimiento pragmático sobre el rol culinario específico que aporta cada elemento concreto. El modelo ignora que el *laurel* actúa exclusivamente como un agente aromatizante (una especia), y propone en su lugar alimentos de consistencia masiva que alteran radicalmente la textura y el concepto del plato. Al basarse en la coocurrencia estadística de palabras en textos gastronómicos, el sistema prioriza ingredientes que encajan armónicamente en el ecosistema global del plato, pero es ciego a la equivalencia funcional exacta de la sustitución (como sí haría el *orégano* en el puesto #7, que comparte su rol de especia).
4. **Alta Densidad Numérica e Inviabilidad de Umbrales Autónomos:** Se observa que los valores de similitud de los primeros puestos tienden a ser numéricamente muy elevados y cercanos entre sí (v.g., en el *Pollo Cocido*, las opciones oscilan de forma muy estrecha entre 0,99889 y 0,99786). Esto se debe a un efecto colateral directo del formato de entrada: dado que el nombre del plato y la gran mayoría de los ingredientes de la lista permanecen fijos e inalterados, la secuencia modificada sigue siendo casi idéntica a la original. Como consecuencia, el modelo genera puntuaciones base muy altas para todas las opciones de la despensa, lo que exige evaluar con precisión los últimos decimales para establecer el orden de preferencia real.

Este fenómeno introduce una limitación crítica para la automatización del sistema: la extrema estrechez de la varianza numérica dificulta enormemente distinguir de forma autónoma entre un sustituto excelente y uno culinariamente inválido. Debido a que la

diferencia matemática es apenas de milésimas, resulta imposible establecer un umbral fijo (*threshold*) estático para discriminar la viabilidad del ingrediente. Por consiguiente, operar estas sustituciones en un entorno puramente no supervisado implicaría un riesgo de introducir falsos positivos para la receta.

6.4.2. Conclusión del Enfoque Basado en Transformers

Los hallazgos experimentales ofrecen una perspectiva interesante sobre el alcance de los modelos de lenguaje bi-direccionales en el dominio gastronómico. Por un lado, se confirma la utilidad de BETO para interpretar el **contexto general** de las recetas, demostrando una capacidad sólida para identificar la atmósfera general del plato. Sin embargo, por otro lado, el modelo manifiesta una limitación en su resolución fina al ser incapaz de ponderar el rol funcional específico del ingrediente faltante. Al guiarse por la coocurrencia estadística de las palabras en el texto, el transformador prioriza la coherencia sintáctica global de la frase, lo que le lleva a proponer sustitutos que encajan en el ecosistema del plato pero que difieren en su uso técnico real.

Esta dualidad en los resultados, sumada a la estrecha varianza numérica en los rankings (donde la diferencia entre opciones válidas e inválidas se reduce a unas pocas milésimas), sugiere que la similitud geométrica de BERT, si bien es una métrica de partida muy potente, no es autosuficiente para operar de forma totalmente autónoma o no supervisada si se busca una precisión culinaria estricta.

Conclusiones

El desarrollo de este Trabajo de Fin de Grado ha permitido analizar de forma progresiva la viabilidad de distintas técnicas de Inteligencia Artificial aplicadas al diseño de un asistente de cocina orientado a la recomendación de recetas a partir de las prioridades logísticas y nutricionales del usuario. Más allá de la implementación de un sistema funcional, la investigación se ha planteado como una exploración metodológica en la que cada fase ha permitido identificar limitaciones concretas y refinar la arquitectura general del recomendador.

En primer lugar, el trabajo ha puesto de manifiesto que la calidad de la recomendación depende de forma crítica de la calidad del dato de entrada. La extracción automática del corpus y su posterior normalización han demostrado que el dominio culinario presenta una elevada heterogeneidad léxica y estructural, lo que imposibilita operar de forma fiable sobre los datos crudos. En este contexto, los enfoques heurísticos basados en reglas han resultado útiles como baseline de limpieza, pero claramente insuficientes para resolver de manera robusta la redundancia y dispersión semántica de los ingredientes. La incorporación de un modelo NER entrenado sobre el dominio permitió reducir de manera significativa estas limitaciones y consolidar una base de conocimiento mucho más coherente y explotable. Esta base de datos ha sido publicada ¹, con el fin de transferir este recurso ya normalizado a la comunidad y servir como punto de partida para futuros desarrollos en este dominio.

En segundo lugar, la comparación entre arquitecturas de embeddings ha permitido concluir que los espacios latentes continuos constituyen una herramienta eficaz para representar afinidades culinarias más allá de la coincidencia exacta de términos. En particular, Word2Vec ha demostrado ofrecer una geometría semántica más adecuada para el núcleo del recomendador, al preservar con mayor fidelidad la separación entre dominios gastronómicos incompatibles y capturar relaciones funcionales de uso culinario de manera más precisa que FastText. Aunque este último presenta ventajas evidentes en términos de robustez morfológica y tratamiento de términos fuera de vocabulario, sus resultados mostraron una tendencia a densificar en exceso el espacio y a reducir la discriminación entre ingredientes contextualmente distintos.

Sobre esta representación semántica, los experimentos de recomendación desarrollados en el Capítulo 5 han confirmado que los enfoques basados exclusivamente en coincidencia exacta resultan demasiado rígidos para un entorno real. La incorporación de medidas continuas de similitud permitió flexibilizar la noción de cobertura del inventario y generar recomendaciones

¹https://github.com/anaherrerozumarraga-hub/ontologia_culinaria

más útiles y variadas. Asimismo, la comparación de distintas estrategias heurísticas puso de relieve que el rendimiento del sistema no depende únicamente del algoritmo de búsqueda elegido, sino también de la interacción entre dicho algoritmo y la topología del espacio de representación. En este sentido, la combinación de Word2Vec con mecanismos de búsqueda local guiada y perturbación controlada demostró ofrecer el equilibrio más sólido entre calidad de recomendación, exploración del espacio y estabilidad de convergencia.

Por otro lado, la ampliación del problema hacia formulaciones multicriterio y multiobjetivo permitió aproximar el recomendador a un escenario de uso más realista. La introducción de restricciones adicionales relacionadas con el tiempo de preparación, la dificultad técnica y el perfil nutricional evidenció que la idoneidad de una receta no puede reducirse al simple solapamiento de ingredientes. En este contexto, las funciones de agregación lineal proporcionaron una primera aproximación operativa, mientras que el análisis mediante Frontera de Pareto permitió representar de forma más fiel los compromisos existentes entre objetivos contrapuestos, evitando la arbitrariedad inherente a la fijación manual de pesos.

Finalmente, la exploración con BETO permitió analizar el potencial de los modelos contextuales basados en Transformers dentro del dominio culinario. Los experimentos realizados mostraron que este tipo de arquitecturas resulta especialmente útil para capturar la coherencia global de una receta y evaluar qué ingredientes encajan dentro de un contexto gastronómico determinado. Sin embargo, también se constató una limitación importante: aunque el modelo es capaz de comprender el entorno semántico general del plato, no siempre distingue con suficiente precisión la función culinaria específica que desempeña un ingrediente concreto dentro de la receta. Esta observación refuerza una de las conclusiones centrales del trabajo: en este problema, la afinidad contextual global y la equivalencia funcional fina no son exactamente la misma tarea y, por tanto, no necesariamente deben resolverse con una única representación.

En conjunto, los resultados obtenidos confirman que la construcción de un asistente de cocina inteligente exige una solución en varias capas: una base de datos limpia y estructurada, una representación semántica robusta de los ingredientes y algoritmos de optimización capaces de operar bajo restricciones reales. El trabajo demuestra que las técnicas de Inteligencia Artificial aplicadas de forma integrada pueden ofrecer una respuesta sólida a este problema, reduciendo la rigidez de los sistemas tradicionales y acercando la recomendación culinaria a un modelo más flexible, interpretable y adaptado al contexto doméstico.

Limitaciones del trabajo

A pesar de los resultados obtenidos, el trabajo presenta algunas limitaciones que deben tenerse en cuenta. En primer lugar, el corpus empleado procede de una única fuente web, lo que condiciona tanto el estilo lingüístico de las recetas como la distribución de ingredientes y categorías culinarias presentes en el sistema. Una mayor diversidad de fuentes permitiría evaluar la robustez del pipeline de normalización en escenarios más heterogéneos.

En segundo lugar, aunque las metaheurísticas implementadas han mostrado un rendimiento satisfactorio en los escenarios evaluados, la validación experimental se ha realizado sobre

inventarios de prueba cerrados y bajo configuraciones controladas. Sería necesario contrastar el comportamiento del sistema con usuarios reales, entradas abiertas y patrones de uso más variables para valorar su utilidad práctica en condiciones de despliegue.

Por último, la exploración con modelos basados en Transformers se ha mantenido en un plano principalmente experimental. Si bien los resultados obtenidos son prometedores en términos de contextualización, no se ha llegado a integrar esta arquitectura en un sistema híbrido plenamente operativo dentro del motor principal de recomendación.

Líneas de trabajo futuro

A partir de los hallazgos obtenidos, se abren diversas líneas de mejora y continuidad. En primer lugar, resultaría de gran interés ampliar y diversificar el corpus de recetas, incorporando nuevas fuentes, estilos de redacción y estructuras culinarias que permitan reforzar la generalización del sistema y evaluar su comportamiento en dominios menos homogéneos.

En segundo lugar, sería pertinente extender la validación del recomendador mediante experimentos con usuarios reales, analizando no solo métricas de ajuste algorítmico, sino también criterios de utilidad percibida, interpretabilidad de las recomendaciones y grado de satisfacción con las sustituciones propuestas.

Finalmente, una línea especialmente prometedora consiste en el diseño de una arquitectura híbrida que combine modelos estáticos y contextuales. En concreto, sería muy interesante desarrollar un sistema que integre Word2Vec y BERT de forma complementaria: utilizando Word2Vec para modelar la afinidad semántica y la compatibilidad global entre ingredientes dentro del espacio culinario, y empleando BERT para contextualizar cada receta y estimar con mayor precisión la función concreta que desempeña cada ingrediente dentro del plato. Un enfoque de estas características podría permitir separar de forma más eficaz la similitud general entre ingredientes de su rol culinario específico, mejorando así la calidad de las sustituciones y la coherencia final de las recomendaciones.

En definitiva, este trabajo establece una base sólida sobre la que seguir construyendo sistemas de recomendación gastronómica más inteligentes, contextuales y adaptados a las necesidades reales del usuario doméstico.

Bibliografía

- [1] Álvaro Fernández-Martínez and José Manuel Gómez-Pérez. Food-bert: Contextualized embeddings for recipe and ingredient representation. *arXiv preprint arXiv:2501.01958*, 2025. Ver páginas [3](#), [4](#).
- [2] Stuart Russell and Peter Norvig. *Artificial Intelligence: A Modern Approach*. Prentice Hall, 3rd edition, 2010. Ver páginas [3](#), [42](#).
- [3] Kalyanmoy Deb. *Multi-Objective Optimization using Evolutionary Algorithms*. John Wiley & Sons, 2001. Ver páginas [3](#), [4](#).
- [4] Zellig S. Harris. Distributional structure. *Word*, 10(2-3):146–162, 1954. Ver páginas [4](#), [23](#).
- [5] Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*, 2013. Ver páginas [4](#), [23](#), and [38](#).
- [6] Tomas Mikolov, Ilya Sutskever, Kai Chen, Greg S. Corrado, and Jeff Dean. Distributed representations of words and phrases and their compositionality. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 3111–3119, 2013. Ver páginas [4](#), [24](#).
- [7] Gerard Salton and Christopher Buckley. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5):513–523, 1988. Ver páginas [4](#), [25](#), and [38](#).
- [8] Jose Camacho-Collados and Mohammad Taher Pilehvar. From word to sense embeddings: A survey on vector representations of meaning. *Journal of Artificial Intelligence Research*, 63:743–830, 2018. Ver página [4](#).
- [9] Omer Levy, Yoav Goldberg, and Ido Dagan. Improving distributional similarity with lessons learned from word embeddings. *Transactions of the Association for Computational Linguistics*, 3:211–225, 2015. Ver páginas [4](#), [24](#), and [38](#).
- [10] El-Ghazali Talbi. *Metaheuristics: From Design to Implementation*. John Wiley & Sons, 2009. Ver página [4](#).
- [11] Carlos A. Coello Coello, Gary B. Lamont, and David A. Van Veldhuizen. *Evolutionary Algorithms for Solving Multi-Objective Problems*. Springer, 2nd edition, 2007. Ver página [4](#).
- [12] Richard S. Barr, Bruce L. Golden, James P. Kelly, Mauricio G. C. Resende, and William R. Stewart. Designing and reporting on computational experiments with heuristic methods. *Journal of Heuristics*, 1(1):9–32, 1995. Ver página [4](#).
- [13] Holger H. Hoos and Thomas Stützle. *Stochastic Local Search: Foundations and Applications*. Morgan Kaufmann, 2004. Ver páginas [4](#), [38](#).
- [14] Scott Kirkpatrick, C. Daniel Gelatt, and Mario P. Vecchi. Optimization by simulated annealing. *Science*, 220(4598):671–680, 1983. Ver páginas [4](#), [45](#).

- [15] Nicholas Metropolis, Arianna W. Rosenbluth, Marshall N. Rosenbluth, Augusta H. Teller, and Edward Teller. Equation of state calculations by fast computing machines. *The Journal of Chemical Physics*, 21(6):1087–1092, 1953. Ver páginas [4](#), [46](#).
- [16] Thomas Bartz-Beielstein. Experimental analysis of optimization algorithms. In *Handbook of Natural Computing*, pages 1473–1501. Springer, 2010. Ver página [4](#).
- [17] Simon Munzert, Christian Rubba, Peter Meißner, and Dominic Nyhuis. *Automated Data Collection with R: A Practical Guide to Web Scraping and Text Mining*. John Wiley & Sons, 2014. Ver página [12](#).
- [18] Ryan Mitchell. *Web Scraping with Python: Collecting More Data from the Modern Web*. O’Reilly Media, 2nd edition, 2018. Ver página [12](#).
- [19] Christopher Olston and Marc Najork. Web crawling. *Foundations and Trends® in Information Retrieval*, 4(3):175–246, 2010. Ver página [12](#).
- [20] Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schütze. *Introduction to Information Retrieval*. Cambridge University Press, 2008. Ver páginas [14](#), [17](#), [23](#), and [32](#).
- [21] Dan Jurafsky and James H. Martin. *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*. Stanford University, 3rd online draft edition, 2024. Ver página [16](#).
- [22] Steven Bird, Ewan Klein, and Edward Loper. *Natural Language Processing with Python*. O’Reilly Media, 2009. Ver páginas [16](#), [17](#), and [24](#).
- [23] George Kingsley Zipf. *Human Behavior and the Principle of Least Effort: An Introduction to Human Ecology*. Addison-Wesley, 1949. Ver página [17](#).
- [24] Prakash M. Nadkarni, Lucila Ohno-Machado, and Wendy W. Chapman. Natural language processing: an introduction. *Journal of the American Medical Informatics Association*, 18(5):544–551, 2011. Ver página [20](#).
- [25] Matthew Honnibal, Ines Montani, Sofie Van Landeghem, and Adriane Boyd. spacy: Industrial-strength natural language processing in python. In *Zenodo*, 2020. Ver página [20](#).
- [26] Max Kuhn and Kjell Johnson. *Applied Predictive Modeling*. Springer, 2013. Ver página [21](#).
- [27] Roderick J. A. Little and Donald B. Rubin. *Statistical Analysis with Missing Data*. John Wiley & Sons, 3rd edition, 2019. Ver página [22](#).
- [28] Jeff Mitchell and Mirella Lapata. Composition in distributional models of semantics. *Cognitive Science*, 34(8):1388–1429, 2010. Ver página [25](#).
- [29] Piotr Bojanowski, Armand Grave, Edouard Joulin, and Tomas Mikolov. Enriching word vectors with subword information. *Transactions of the Association for Computational Linguistics*, 5:135–146, 2017. Ver páginas [27](#), [29](#), and [31](#).
- [30] Amit Singhal. Modern information retrieval: A brief overview. *IEEE Data Engineering Bulletin*, 24(4):35–43, 2001. Ver página [38](#).
- [31] Michel Gendreau and Jean-Yves Potvin. *Handbook of Metaheuristics*, volume 146. Springer, 2010. Ver página [42](#).
- [32] Helena R. Lourenço, Olivier C. Martin, and Thomas Stützle. Iterated local search. In *Handbook of Metaheuristics*, pages 320–353. Springer, 2003. Ver página [42](#).
- [33] Vladimír Černý. Thermodynamical approach to the traveling salesman problem: An efficient simulation algorithm. *Journal of Optimization Theory and Applications*, 45(1):41–51, 1985. Ver página [45](#).

- [34] Franco Buseti. Simulated annealing overview. Technical report, University of the Witwatersrand, 2003. Ver página [46](#).
- [35] Emile Aarts and Jan Korst. *Simulated Annealing and Boltzmann Machines: A Stochastic Approach to Combinatorial Optimization and Neural Computing*. John Wiley & Sons, 1989. Ver página [47](#).
- [36] Kalyanmoy Deb. *Multi-Objective Optimization Using Evolutionary Algorithms*, volume 16. John Wiley & Sons, 2001. Ver página [54](#).
- [37] José Cañete, Gabriel Chaperon, Rodrigo Fuentes, Jou-Hui Hoernle, Néstor Jorge, and Jorge Pérez. Spanish language models. *arXiv preprint arXiv:2008.03573*, 2020. Ver página [61](#).
- [38] Ashish Vaswani et al. Attention is all you need. In *Advances in neural information processing systems*, pages 5998–6008, 2017. Ver página [62](#).
- [39] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*, 2018. Ver página [62](#).